

3º Presentación

Deep learning



Presentadores
Alan Acuña
Felipe Mena


Objetivo:

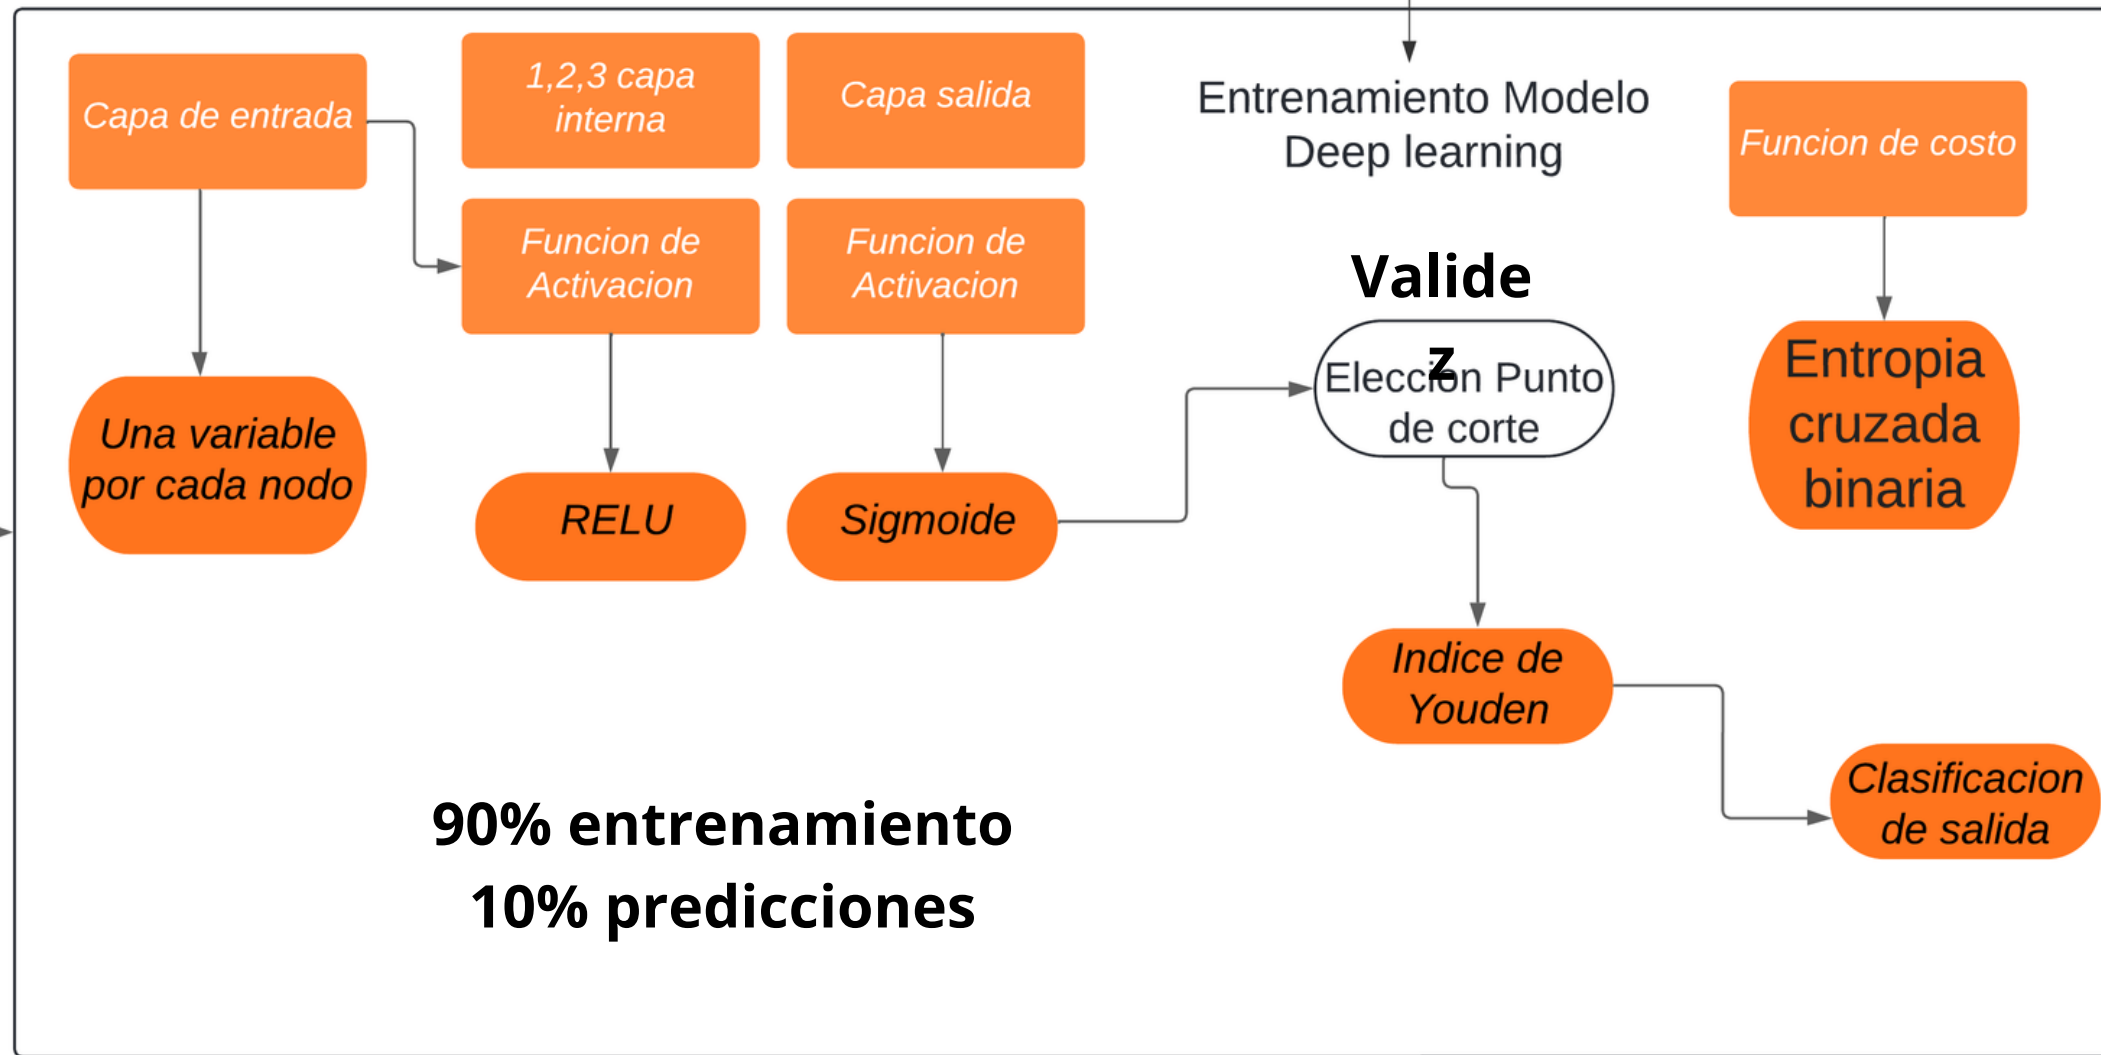


Identificar cuentas fraudulentas en el contexto de criptomonedas de la plataforma ethereum comparando el poder predictivo de modelo de redes neuronales con el modelo SVM y modelo logistico , en base a esto escoger el modelo que mejor clasifica.


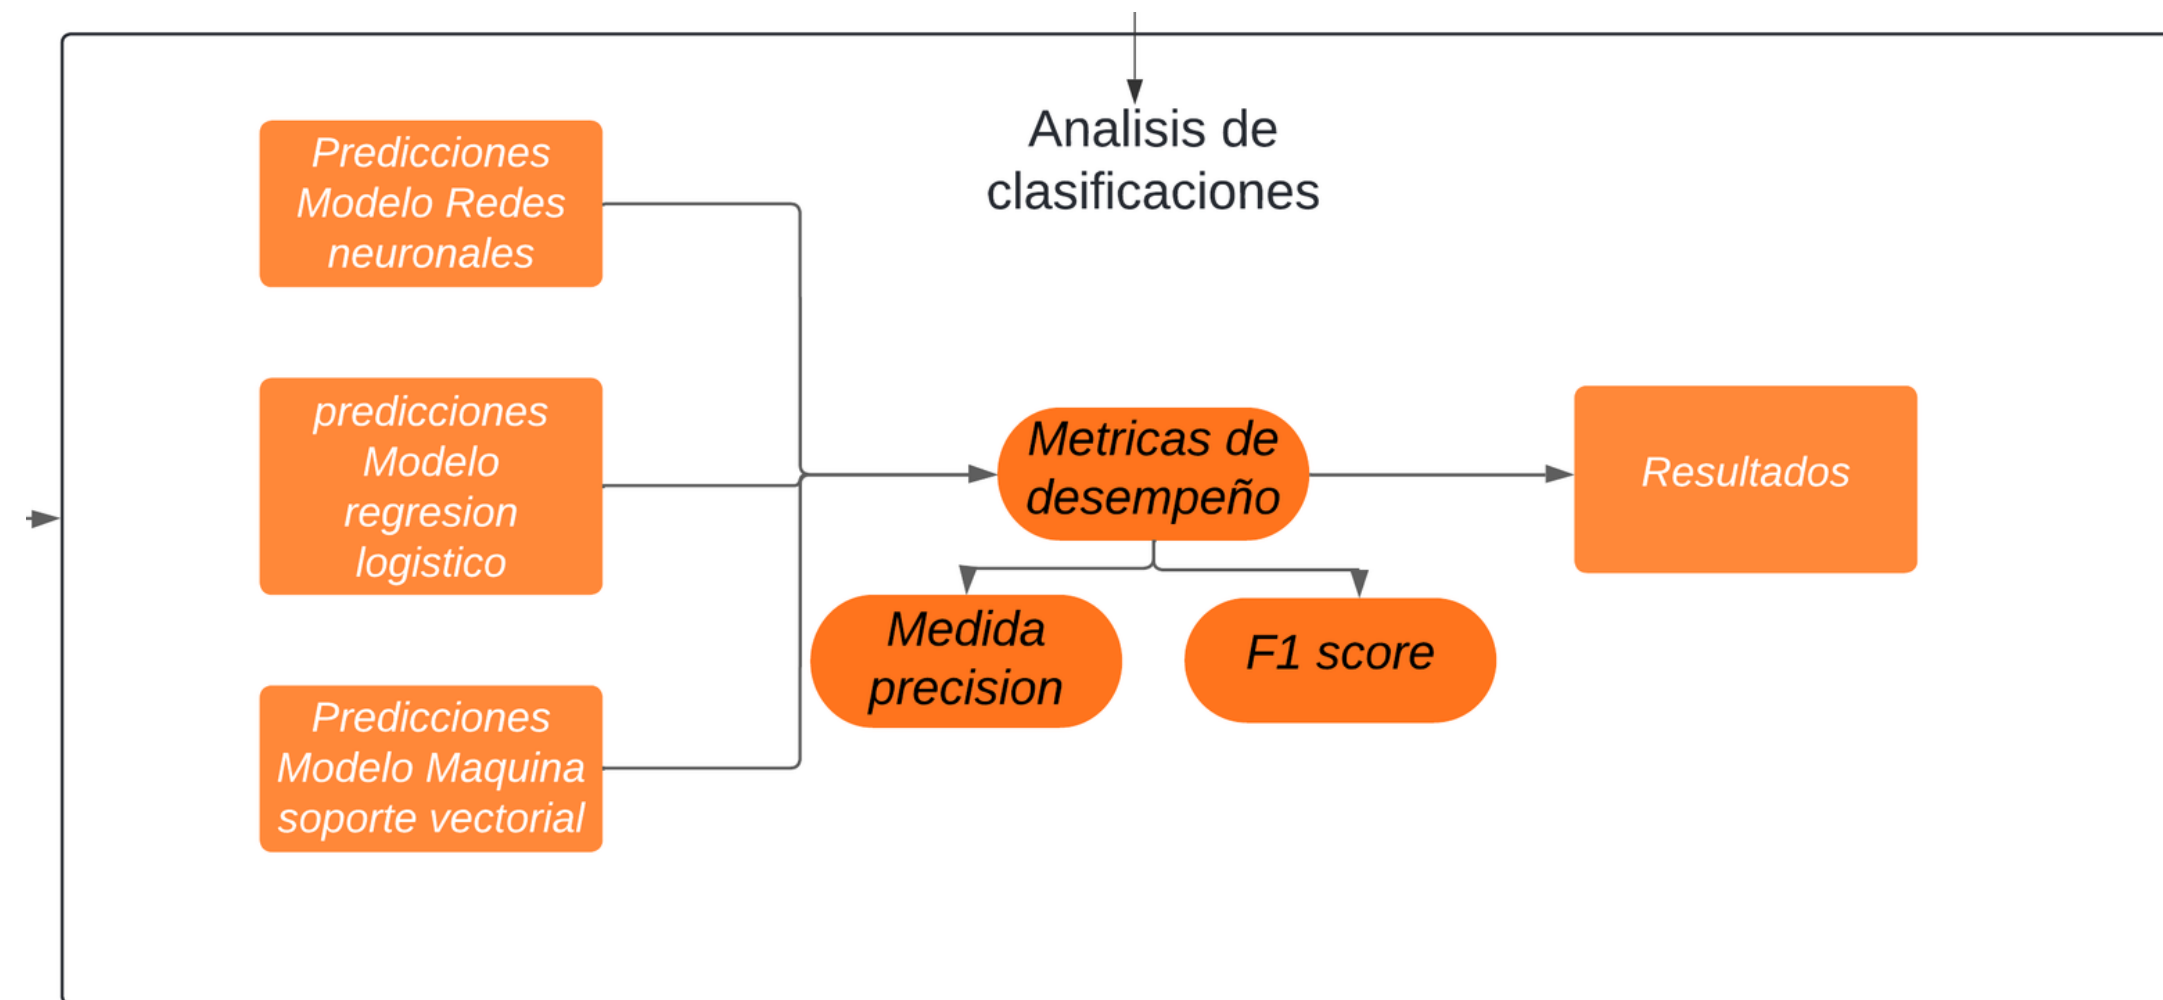
Hipotesis:

Evaluar si el modelo de redes neuronales de tres capas internas tiene un mejor desempeño en predecir frente al modelo logístico y SVM






Esquema Metodologico



Definición de Arquitectura




Función de activación


$$f(Z) = \frac{1}{1 + \exp(-Z)} \quad \phi(v) = \max\{0, v\}$$

Método Regularizador Dropout

- Capa de entrada: 5 neuronas
- 1 capa interna: 50 neuronas | tasa 30%
- 2 capa interna: 32 neuronas | tasa 30%
- 3 capa interna: 20 neuronas | tasa 30%
- Capa de salida: 1 neurona



(a) Standard Neural Net



(b) After applying dropout.

Definición de Arquitectura


Modelo SVM

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$$

Kernel:Radial


Gamma:10

Función Costo:20



Modelo Regresión logística

$$\mathbb{P}(Y = 1|X_1, \dots, X_k) = \frac{e^{\beta_0 + \vec{x}\beta}}{1 + e^{\beta_0 + \vec{x}\beta}} \quad \mathbb{P}(Y = 0|X_1, \dots, X_k) = \frac{1}{1 + e^{\beta_0 + \vec{x}\beta}}$$



Descripción del proceso de entrenamiento

Modelos de redes neuronales

Función de Costo:

$$-\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Épocas: 200

Algoritmo de optimización: Adam

$$w_{t+1} = w_t - \alpha_t \frac{\tilde{u}}{\sqrt{\tilde{v} + \epsilon}}$$

learning rate= 0.001

beta 1 = 0.9

beta 2 = 0.999


Tiempo de cómputo: 4.09 minutos

Procesador PC: AMD Ryzen 5 2500U

Metricas:

$$Precision = \frac{VP}{VP + FP}$$

$$F1_{score} = 2 \frac{Precision * S}{Precision + S}$$



Valores Reales	Valores Predichos		Totales
	Negativo $\hat{Y} = 0$	Positivo $\hat{Y} = 1$	
Negativo Y=0	Verdaderos Negativo (VN)	Falsos Positivo (FP)	VN+FP
Positivo Y=1	Falso Negativo (FN)	Verdadero Positivo (VP)	FN+VP

Descripción del proceso de entrenamiento



Modelo/ Descripción	Modelo SVM y logístico	
	SVM	Logístico
Tiempo de computo	20.44 Segundos	3.45 Segundos

SVM


Código en R

```
cost_svm=tune(svm,factor(fraude_train[,1])~fraude_train[,2]+fraude_train[,3]+fraude_train[,4]+
fraude_train[,5],data=fraude_train,
kernel = 'radial',ranges=list(cost = c(20),gamma = c(0.20,0.5, 1, 2, 3, 4, 5, 10)))
plot(cost_svm)

tiempo_ini_SVM= Sys.time()
mod_svm=svm(as.factor(fraude_train[,1])~.,data=fraude_train[, -1],kernel='radial',
, cost=20, gamma=10, decision.values=T, probability=T)
tiempo_fin_SVM= Sys.time()
tiempo_SVM=tiempo_ini_SVM-tiempo_fin_SVM
```

Logístico:

```
tiempo_ini_log= Sys.time()
mod_logistic=glm(fraude_train[,1]~fraude_train[,2]+fraude_train[,3]+fraude_train[,4]+
fraude_train[,5]+fraude_train[,6],family=binomial(link='logit'))
tiempo_fin_log= Sys.time()
```



Proceso de entrenamiento y validación



Código de Modelo de Redes Neuronales

R:

```
mod_RN2=keras_model_sequential()  
mod_RN2%>%layer_dense(units = 5,activation = 'relu',input_shape = c(5))%>%  
  layer_dense(units = 50,activation = 'relu')%>%layer_dropout(rate=0.3)%>%  
  layer_dense(units=32,activation='relu')%>%  
  layer_dropout(rate=0.3)%>%  
  layer_dense(units=20,activation='relu')%>%  
  layer_dropout(rate=0.3)%>%  
  layer_dense(units=1,activation='sigmoid')
```

```
mod_RN2%>%compile(loss = 'binary_crossentropy',metrics=c('accuracy'),optimizer=optimizer_adam()  
)  
tiempo_ini_RNN= Sys.time()  
  
historia=mod_RN2%>%fit(as.matrix(fraude_train[,-1]),as.matrix(fraude_train[,1]),epochs=200,  
  batch_size = 100,validation_split=0.10  
,callbacks = callback)  
plot(historia)  
  
tiempo_fin_RNN= Sys.time()  
tiempo_fin_RNN-tiempo_ini_RNN
```

**loss: 0.3886 - accuracy: 0.8370 -
val_loss: 0.4074 - val_accuracy: 0.8262**

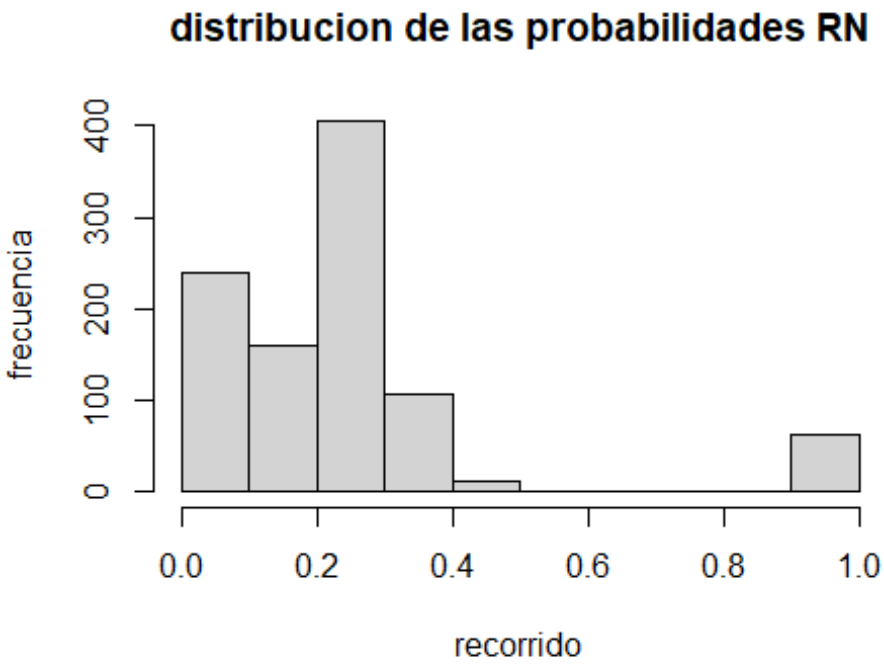




Procedimiento de discriminacion del modelo

Código de R:

```
prob_2RN = mod_RN2 %>%  
  predict(as.matrix(fraude_test[, -1])) %>%  
  array_reshape(., dim = c(985, 1)) %>%  
  as.vector()  
library(pROC)  
roc_RN2=roc(as.matrix(fraude_test[, 1]), prob_2RN)  
plot.roc(roc_RN2, print.auc = T, print.thres = 'best', main='Curva AUC modelo RN', xlim=c(1,0))
```



```
predic_RN2=ifelse(prob_2RN>=0.253,1,0)  
library(caret)  
cf_RN=confusionMatrix(as.factor(predic_RN2), as.factor(as.matrix(fraude_test[, 1])), positive='1')
```

Pred/Ref	0	1
0	541	22
1	195	227

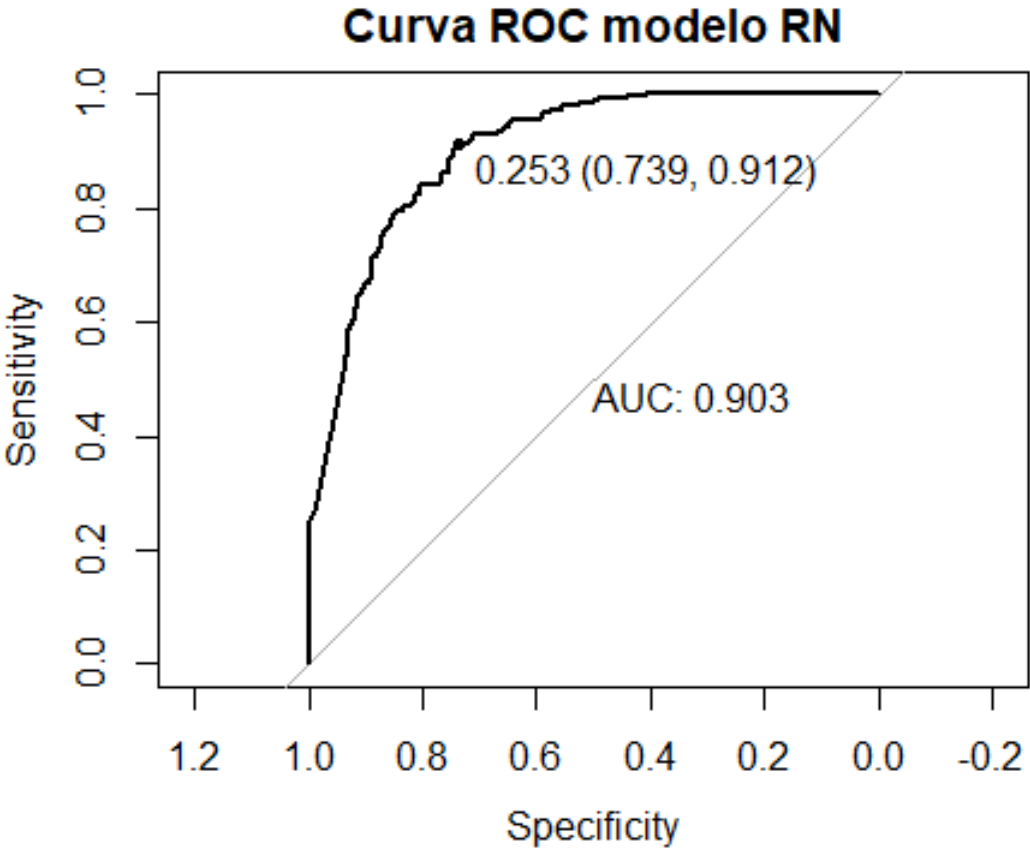
Sensibilidad:0.911
Especificidad: 0.7351

Precisión:0.537
F1 Score:0.6766

$$Precision = \frac{VP}{VP + FP}$$

$$F1_{score} = 2 \frac{Precision * S}{Precision + S}$$


Valores Reales	Valores Predichos		Totales
	Negativo $\hat{Y} = 0$	Positivo $\hat{Y} = 1$	
Negativo Y=0	Verdaderos Negativo (VN)	Falsos Positivo (FP)	VN+FP
Positivo Y=1	Falso Negativo (FN)	Verdadero Positivo (VP)	FN+VP



Validación de Modelos

Redes Neuronales


Curva ROC modelo RN



Pred/Ref	0	1
0	541	22
1	195	227

SVM

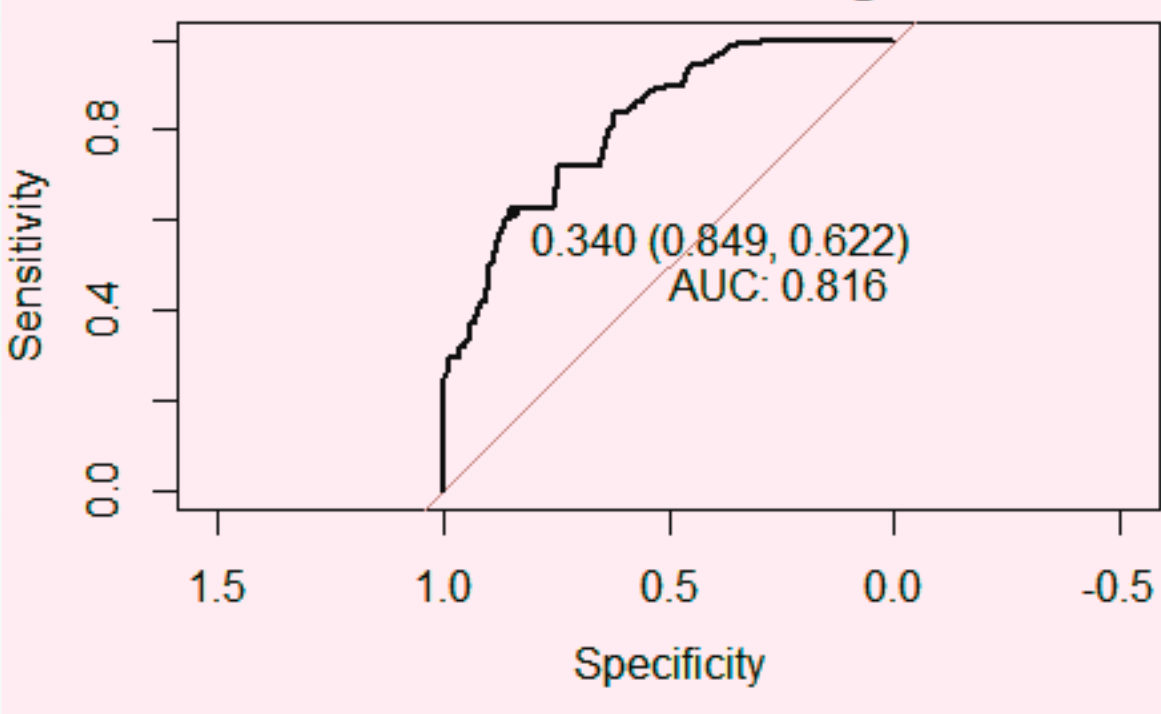
Curva ROC SVM



Pred/Ref	0	1
0	590	29
1	146	220

Logístico

Curva AUC Modelo logístico



Pred/Ref	0	1
0	625	94
1	111	155

Validación de Modelos

Redes Neuronales

Pred/Ref	0	1
0	541	22
1	195	227

Sensibilidad:0.911
Especificidad: 0.7351

Precisión:0.537
F1 Score:0.6766

SVM

Pred/Ref	0	1
0	590	29
1	146	220

Sensibilidad: 0.888
Especificidad: 0.802

Precisión: 0.601
F1 Score: 0.715

Logístico

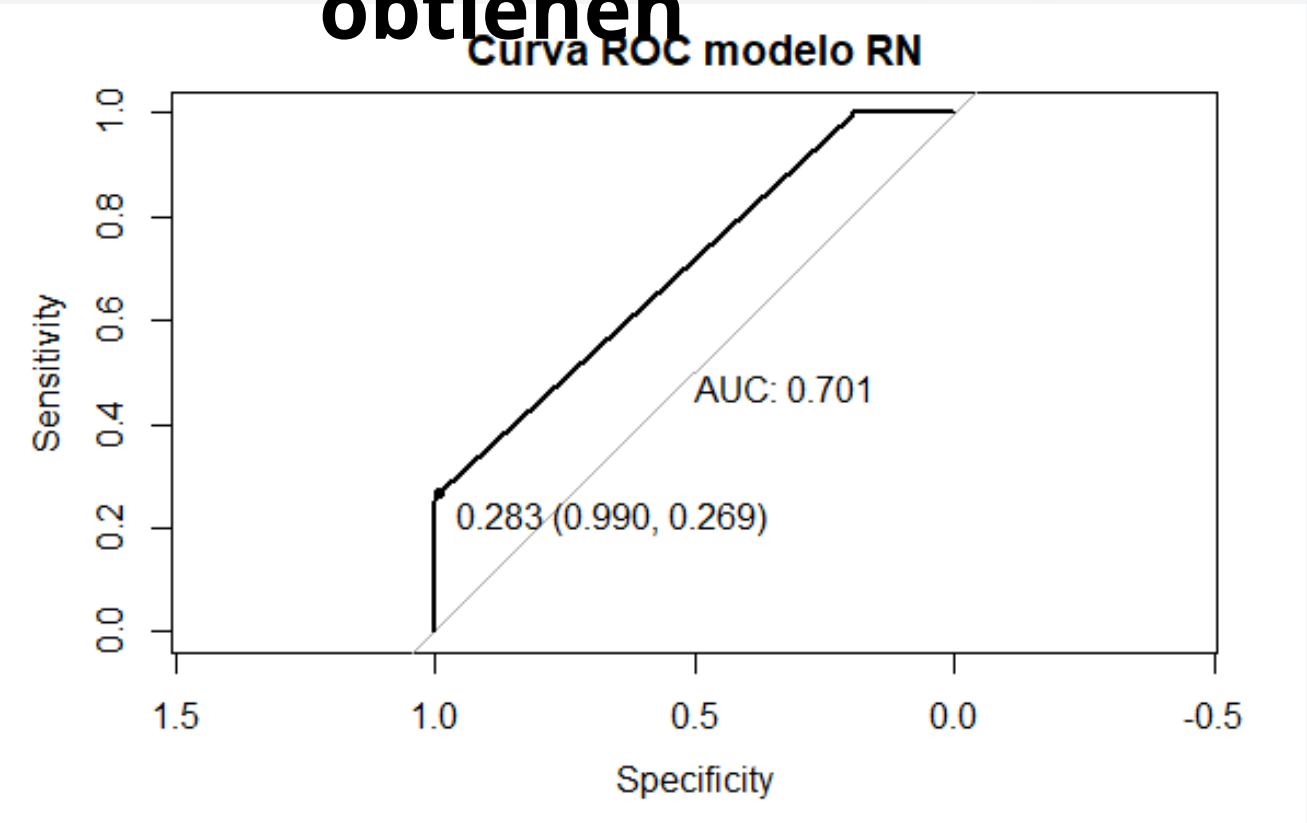

Pred/Ref	0	1
0	625	94
1	111	155

Sensibilidad: 0.622
Especificidad: 0.849

Precisión: 0.582
F1 Score: 0.601

Curva roc de las predicciones de modelos ajustados que usualmente se obtienen

Ajuste modelo habitual

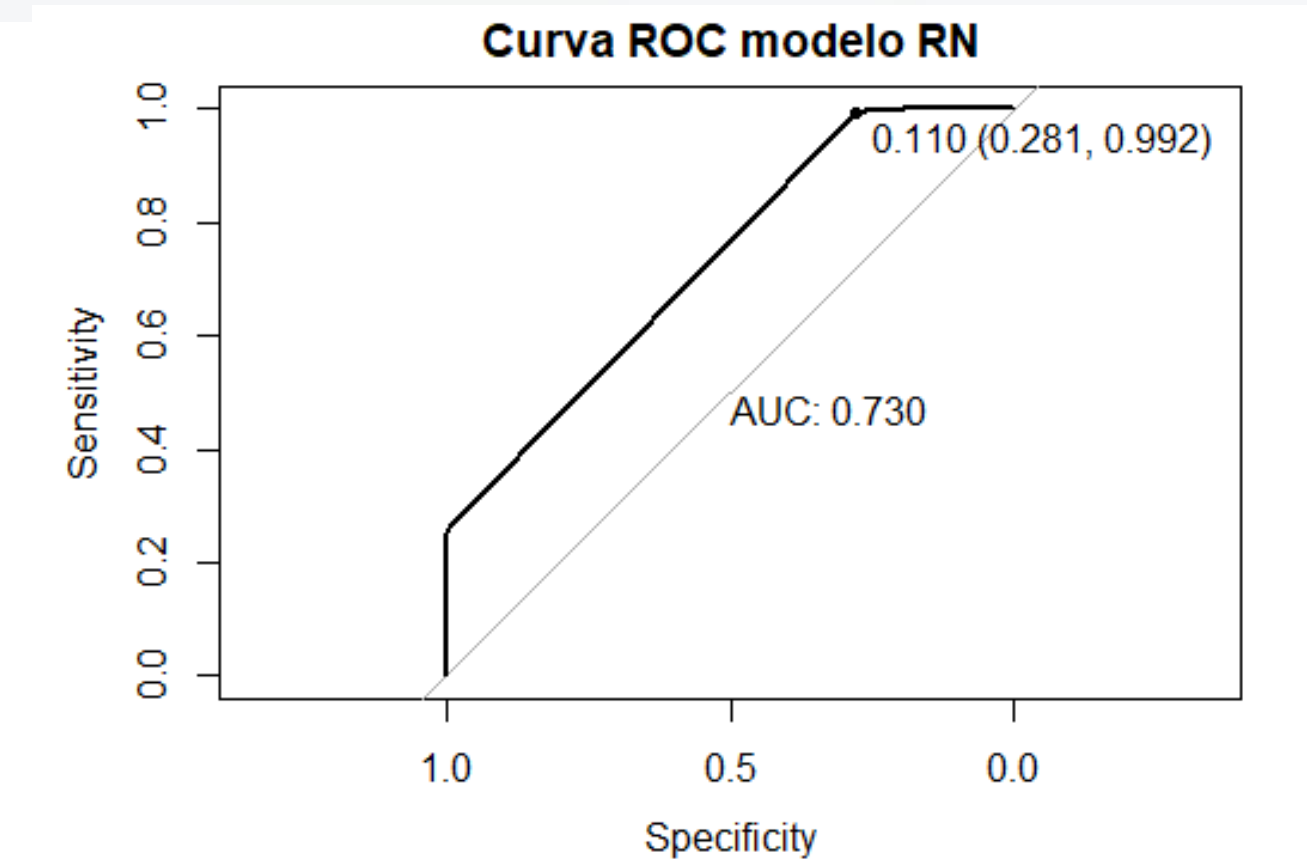



Pred/Ref	0	1
0	729	182
1	7	67

Sensibilidad:0.269
Especificidad: 0.990

Precisión:0.9054
F1 Score:0.4148

Ajuste modelo habitual



Pred/Ref	0	1
0	209	2
1	529	247

Sensibilidad:0.992
Especificidad: 0.281

Precisión:0.3182
F1 Score:0.4819

Estado del Arte

- Developing a Credit Card Fraud Detection Model using Machine Learning Approaches

Modelo
Logístico
F1 Score: 0.722

Pred/Ref	0	1
0	284271	44
1	189	303

SV
F1 Score: 0.826

Pred/Ref	0	1
0	284261	54
1	108	384

Redes Neuronales
F1 Score: 0.763

Pred/Ref	0	1
0	284203	112
1	119	373

LGBM: a machine learning approach for Ethereum fraud detection

Modelo
Logístico
F1 Score: 0.960
Precisión: 0.923

SV
F1 Score: 0.557
Precisión: 0.994

Redes Neuronales
F1 Score: 0.883
Precisión: 0.922

Exploring the Application of Neural Network in Detecting Fraudulent within the Ethereum Network

Ref/pred	0	1
0	1477	86
1	42	363

SV
Sensibilidad: 0.8085
Especificidad: 0.9724

Redes Neuronales


Ref/pred	0	1
0	1503	306
1	16	143

Sensibilidad: 0.3185
Especificidad: 0.9895



Conclusión:

- Objetivos
- Hipotesis
- La importancia del falso negativo
- Mejoras : Sin limitaciones de capas
- Modelo de random Forest.



Valores Reales	Valores Predichos		Totales
	Negativo $\hat{Y} = 0$	Positivo $\hat{Y} = 1$	
Negativo $Y=0$	Verdaderos Negativo (VN)	Falsos Positivo (FP)	VN+FP
Positivo $Y=1$	Falso Negativo (FN)	Verdadero Positivo (VP)	FN+VP