



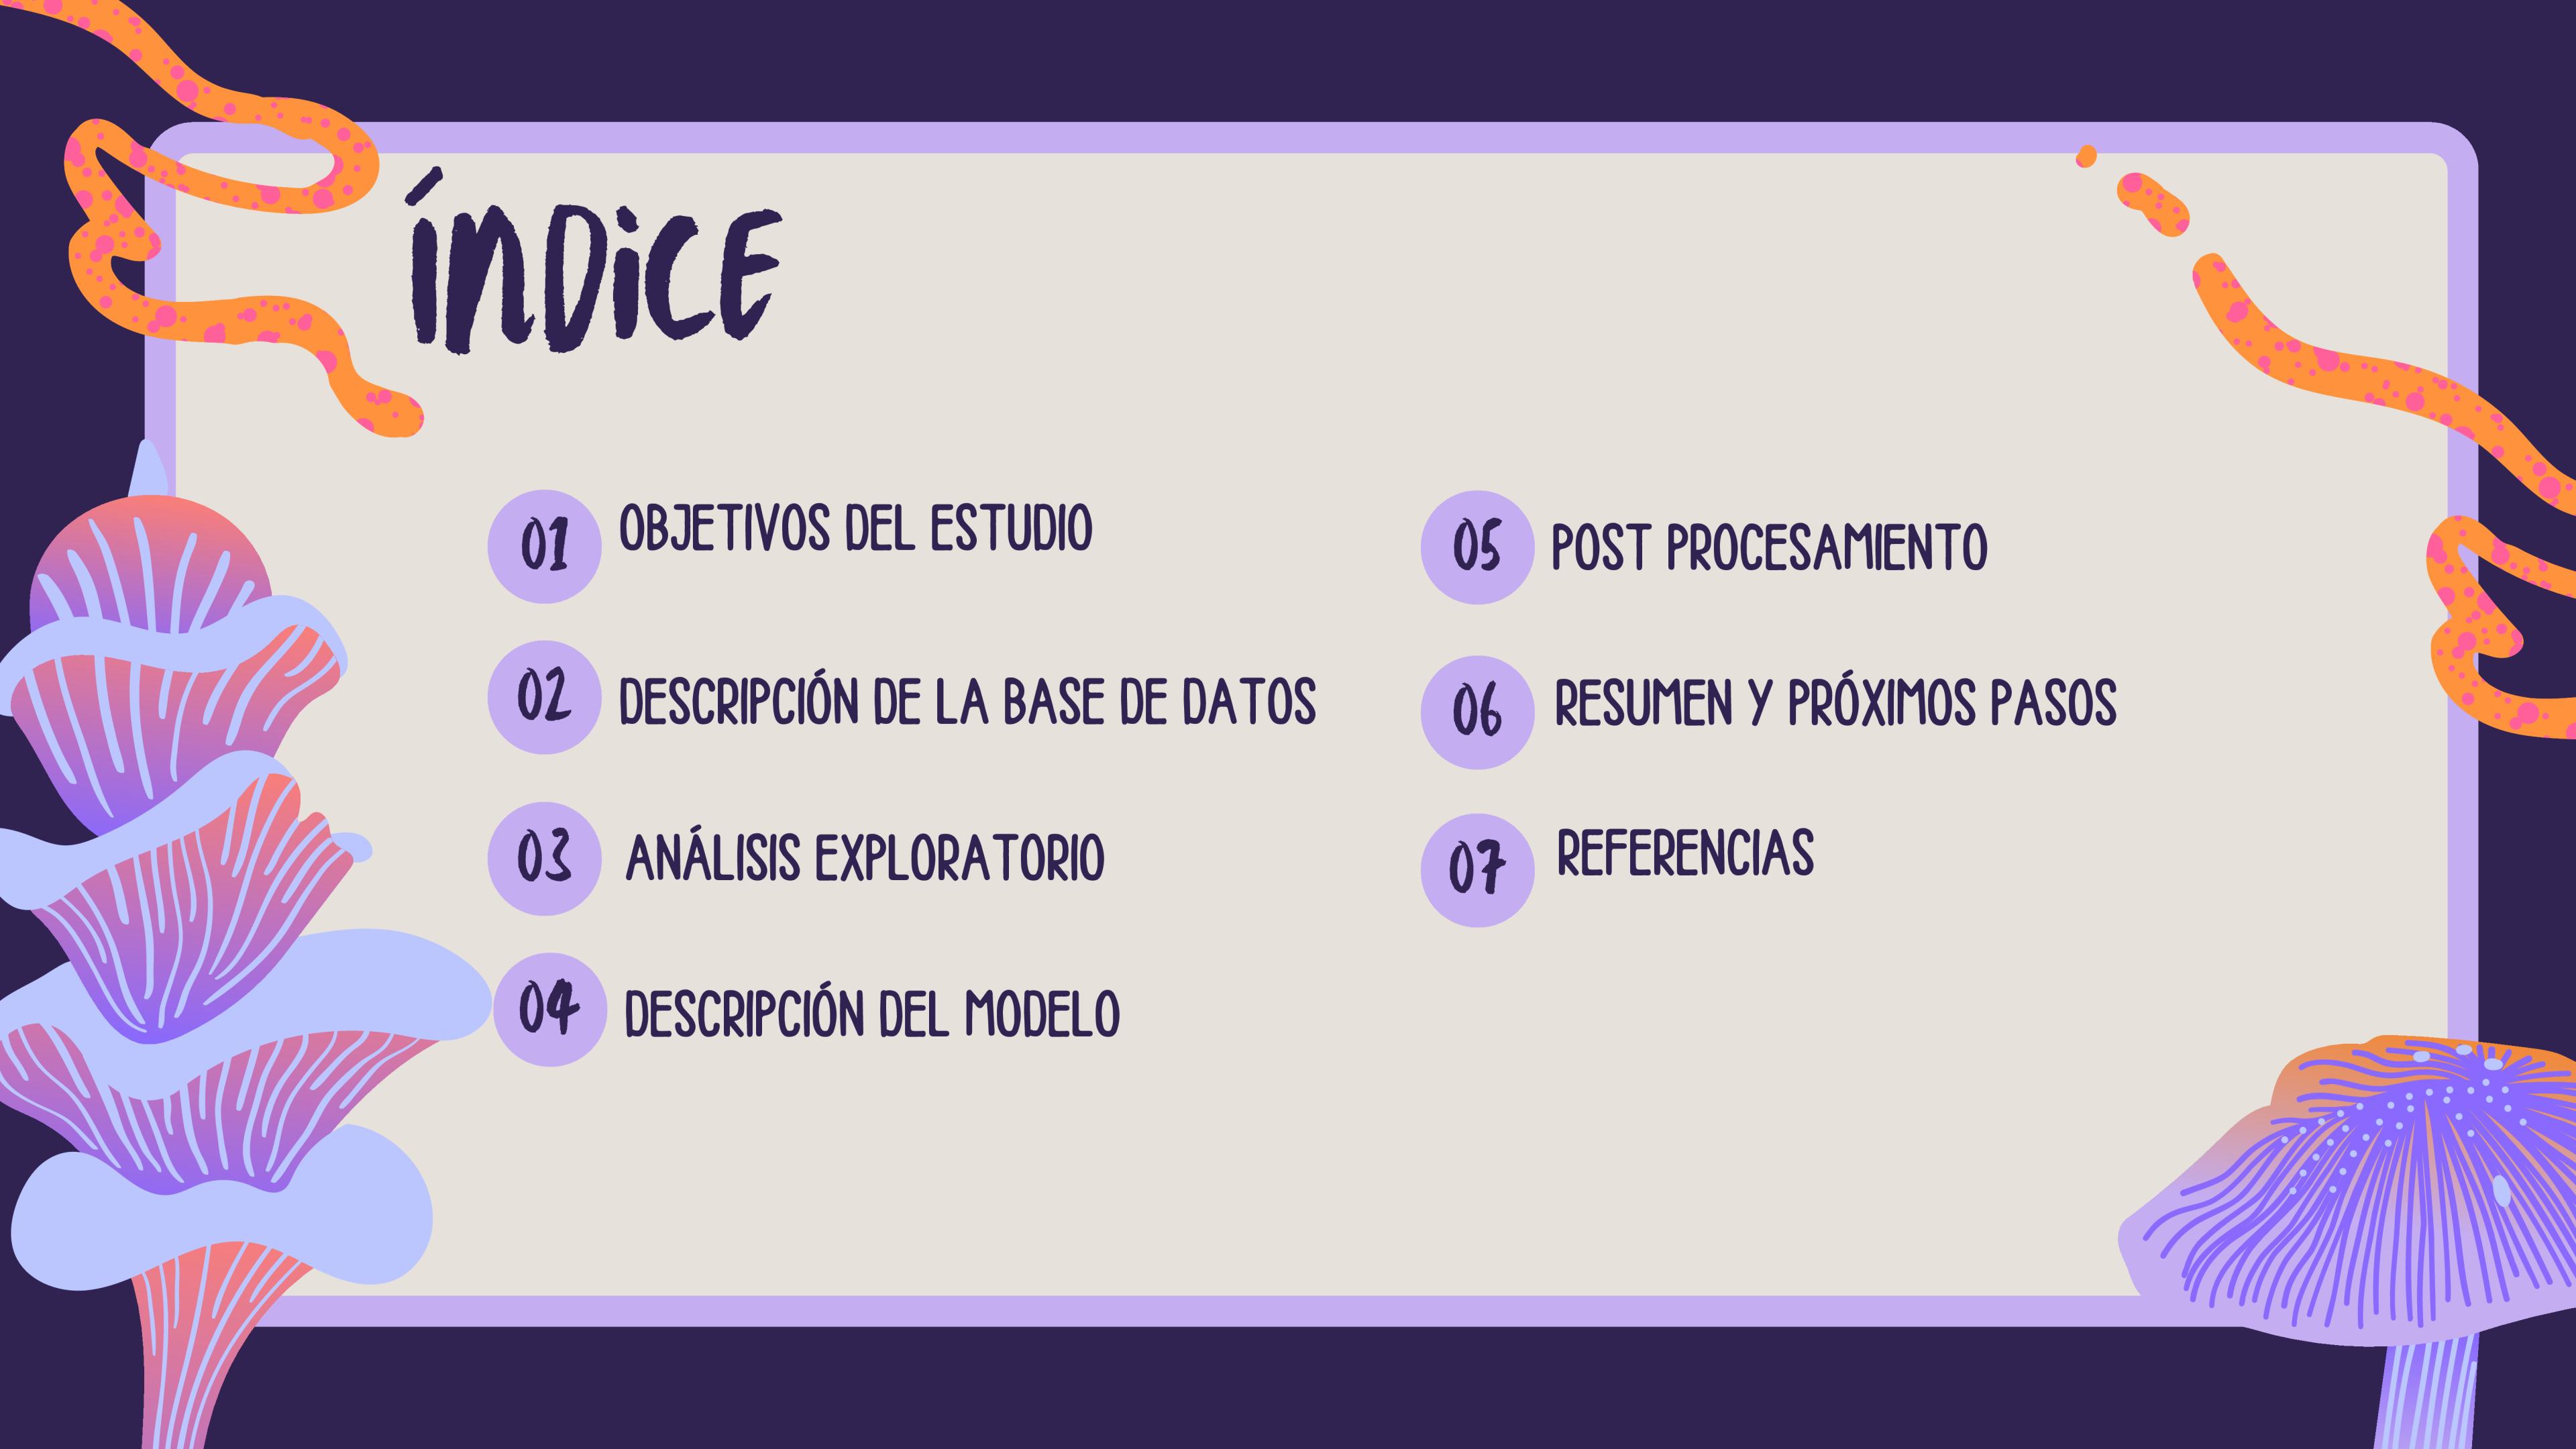
UNIVERSIDAD DE SANTIAGO DE CHILE
DEPARTAMENTO DE MATEMÁTICA Y CIENCIAS DE LA COMPUTACIÓN
INGENIERÍA ESTADÍSTICA

DEEP LEARNING

CLASIFICACIÓN INTELIGENTE DE IMÁGENES DE HONGOS: UNA APLICACIÓN DE REDES NEURONALES CONVOLUCIONALES

JUAN CEBALLOS
CATALINA PIVTRÍN
NICOLÁS SAGREDO

índice

- 
- 01 OBJETIVOS DEL ESTUDIO
 - 02 DESCRIPCIÓN DE LA BASE DE DATOS
 - 03 ANÁLISIS EXPLORATORIO
 - 04 DESCRIPCIÓN DEL MODELO
 - 05 POST PROCESAMIENTO
 - 06 RESUMEN Y PRÓXIMOS PASOS
 - 07 REFERENCIAS

OBJETIVO GENERAL

- CLASIFICAR IMÁGENES
MICROSCÓPICAS DE HONGOS DENTRO
DE 5 CATEGORÍAS MEDIANTE UN
MODELO DE CNN

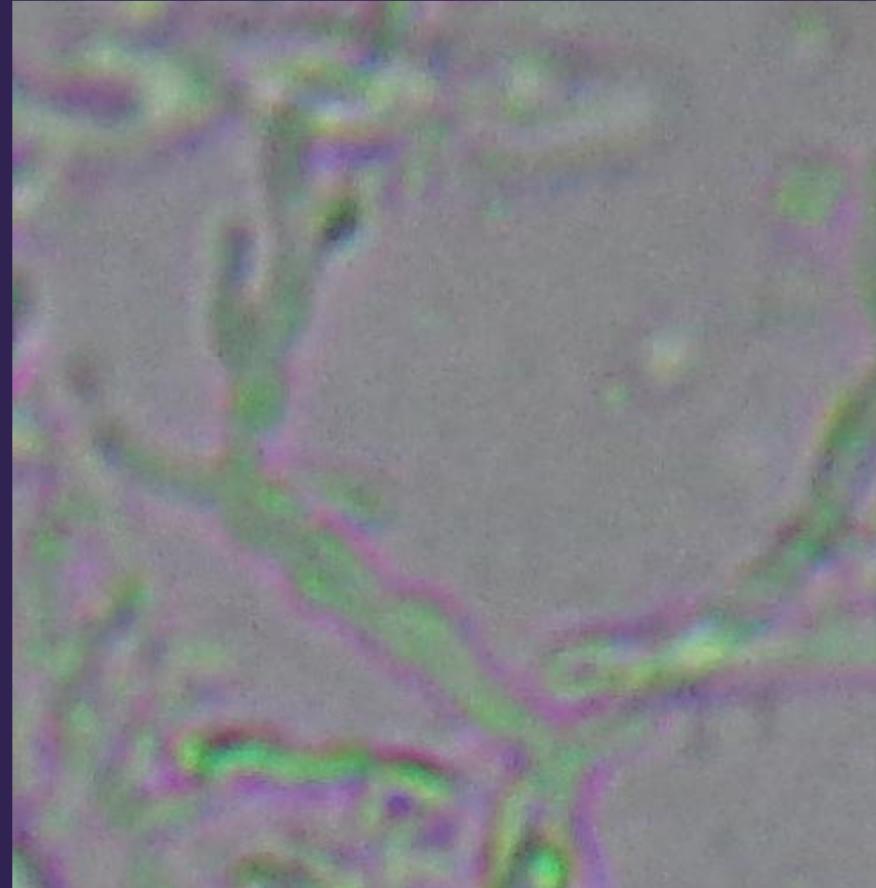
OBJETIVOS ESPECÍFICOS

- ANALIZAR LA INFORMACIÓN DISPONIBLE SOBRE TIPOS DE HONGOS
- IMPLEMENTAR AL MENOS DOS MODELOS DE CNN PARA LA CLASIFICACIÓN DE HONGOS
- ENTRENARLOS DESDE CERO
- EVALUARLOS SEGÚN MÉTRICAS DE DESEMPEÑO (ACCURACY, PRESICION Y RECALL POR CLASE, ETC)
- COMPARAR Y CONSERVAR EL MEJOR MODELO

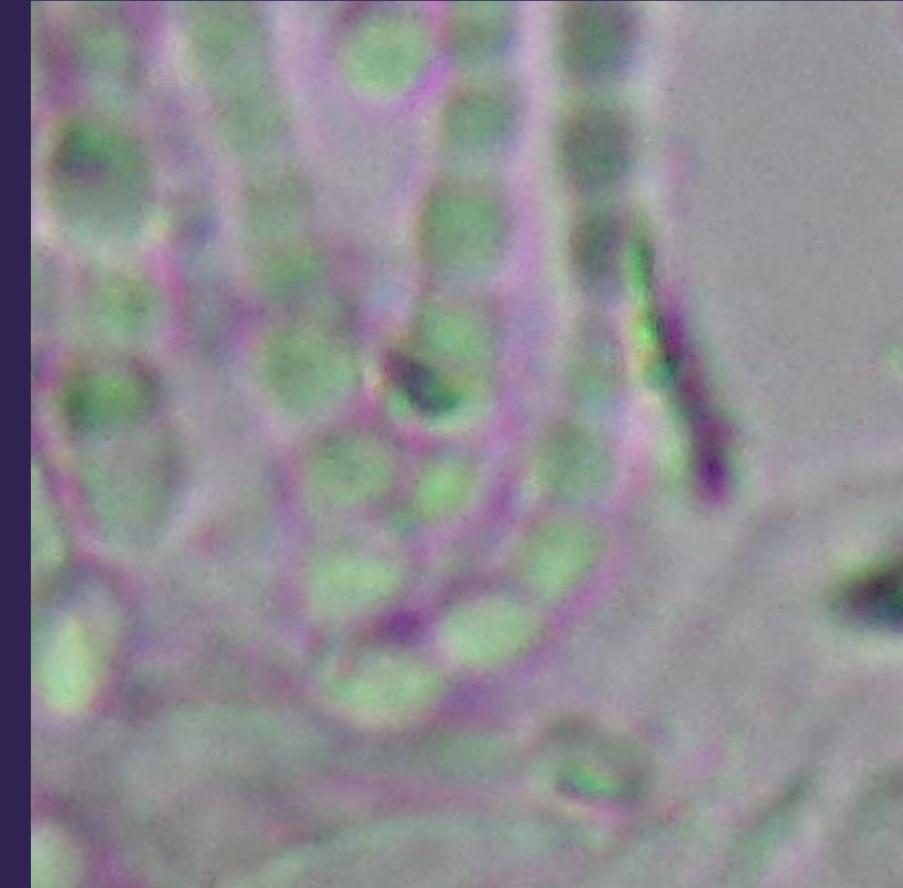


DESCRIPCIÓN DE LA BASE DE DATOS

HIFAS HIALINAS SEPTADAS
TORTUOSAS [H1]

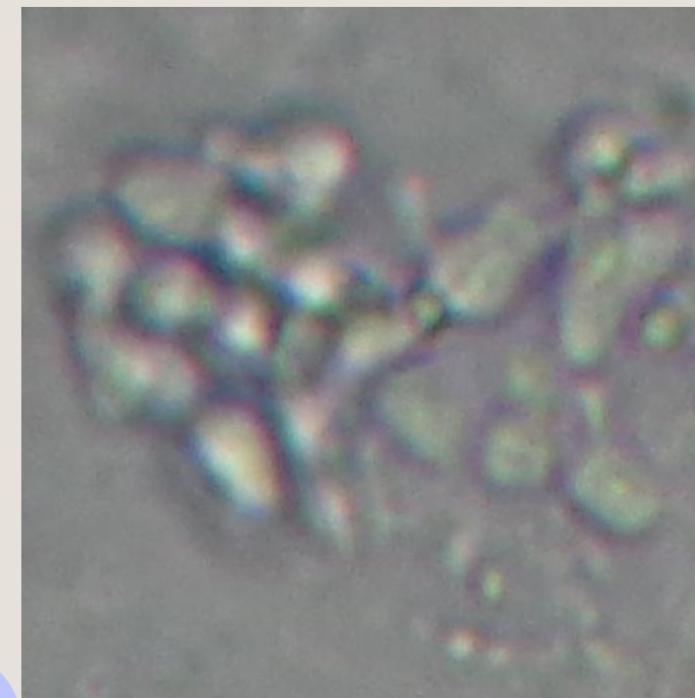


HIFAS HIALINAS SEPTADAS
EN CUENTAS [H2]

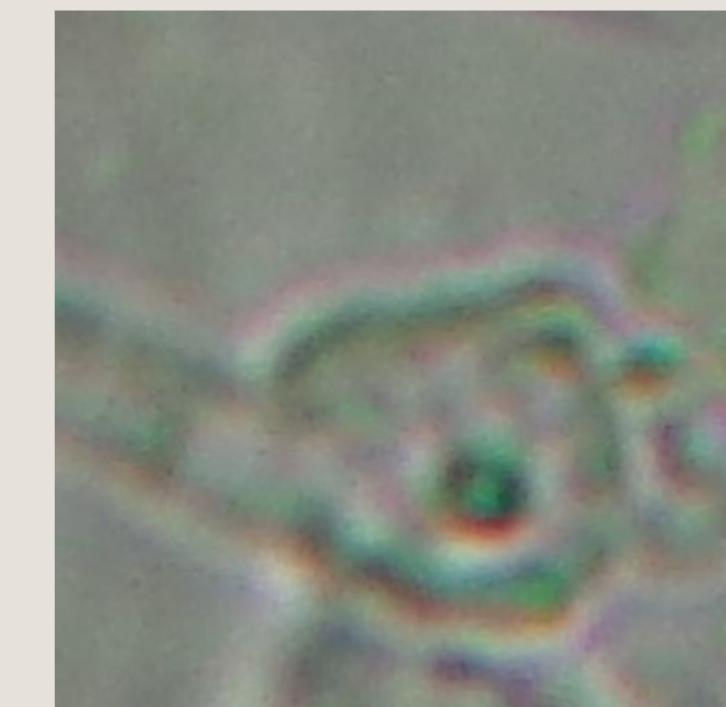


DESCRIPCIÓN DE LA BASE DE DATOS

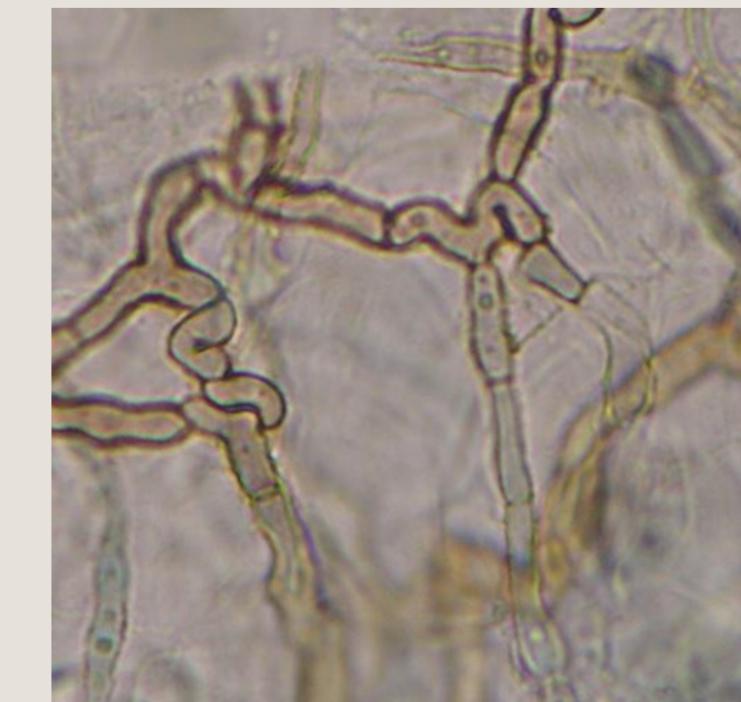
GRUPOS O MOSAICOS DE
ARTROCONIDIAS (H3)



HIFAS HIALINAS SEPTADAS
CON CHLAMYDIOCONIDIAS
(H5)

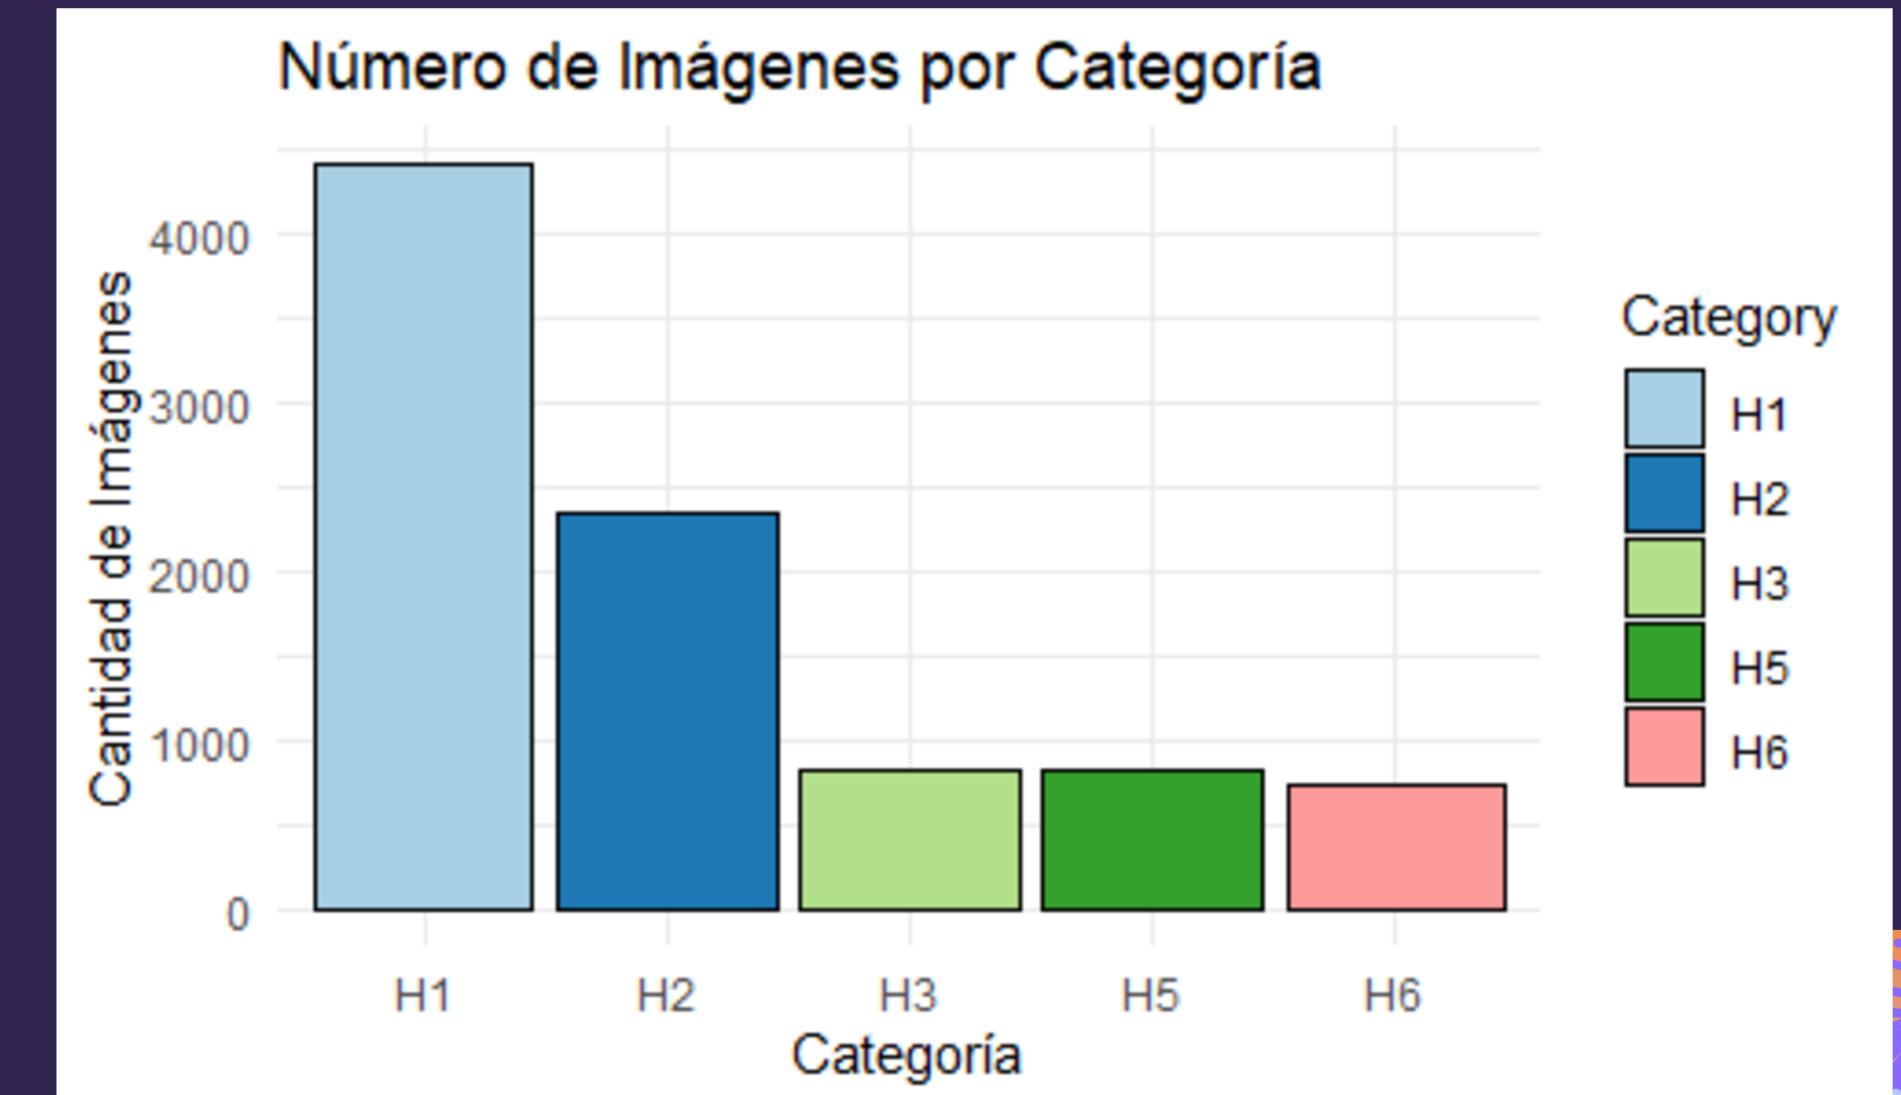


HIFAS ANCHAS
MARRONES (H6)

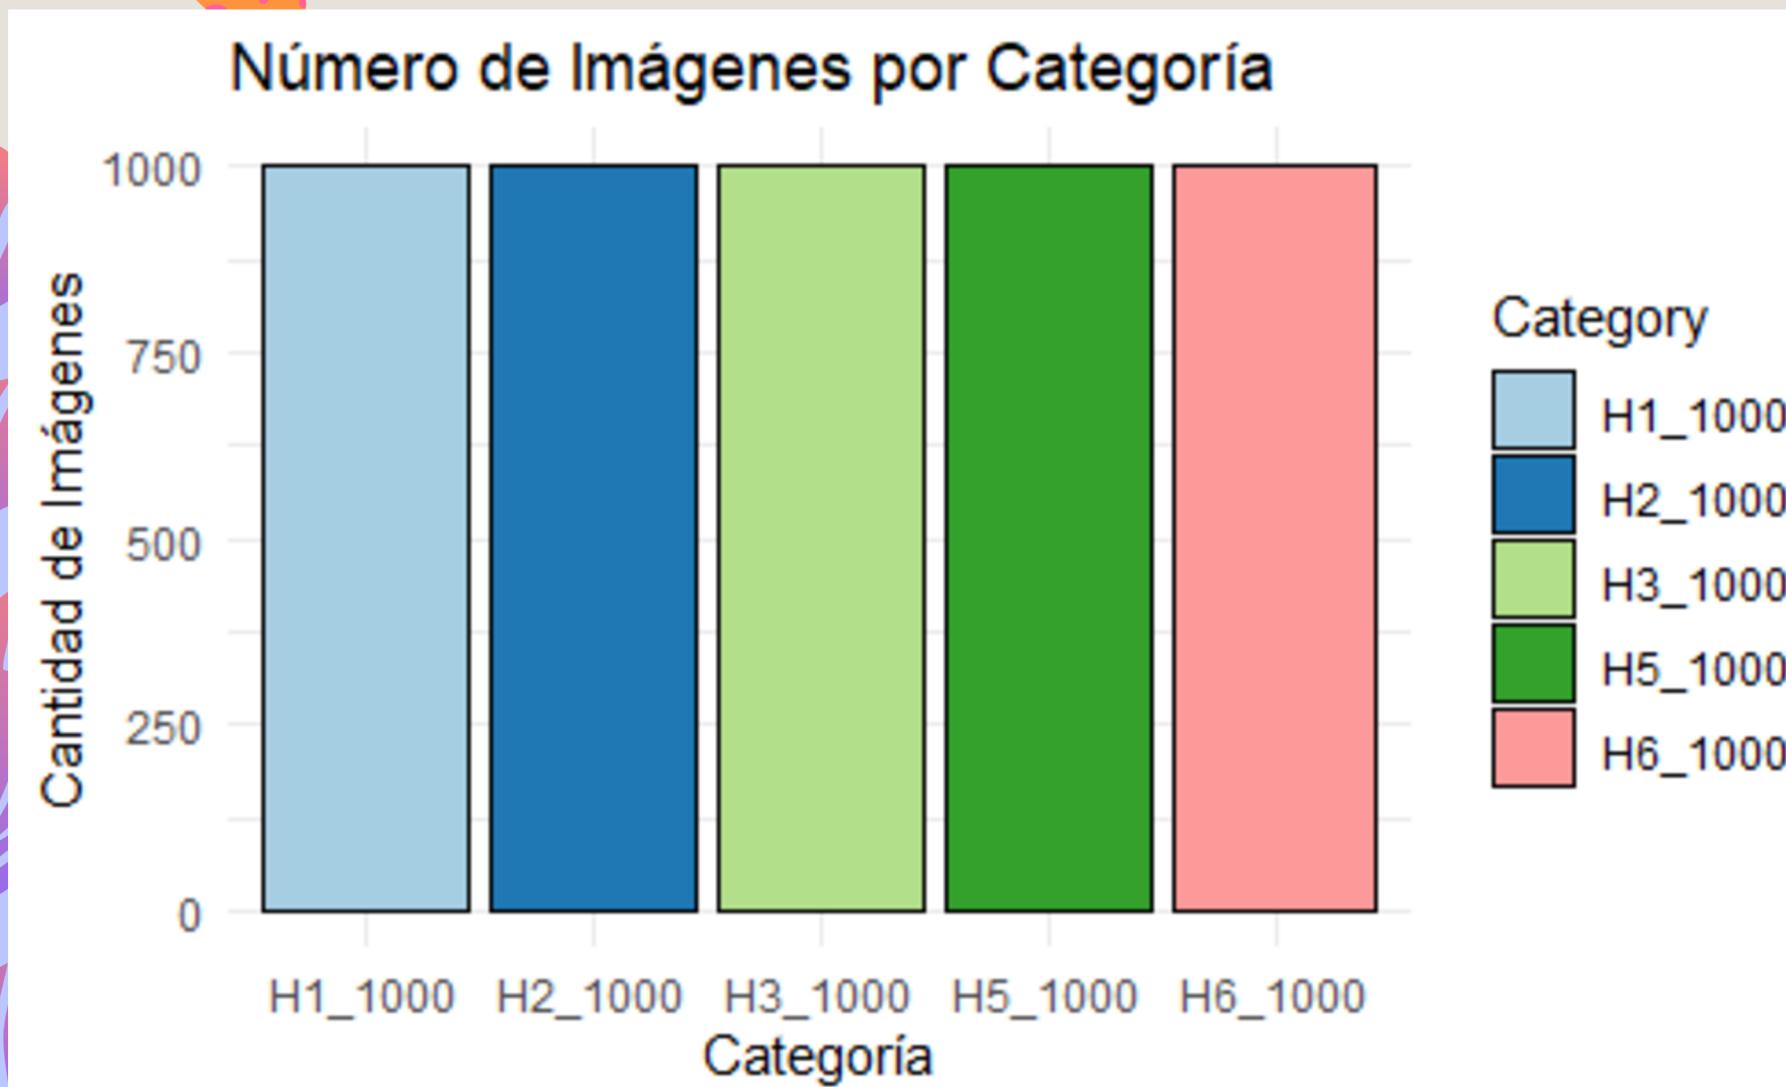


DESCRIPCIÓN DE LA BASE DE DATOS

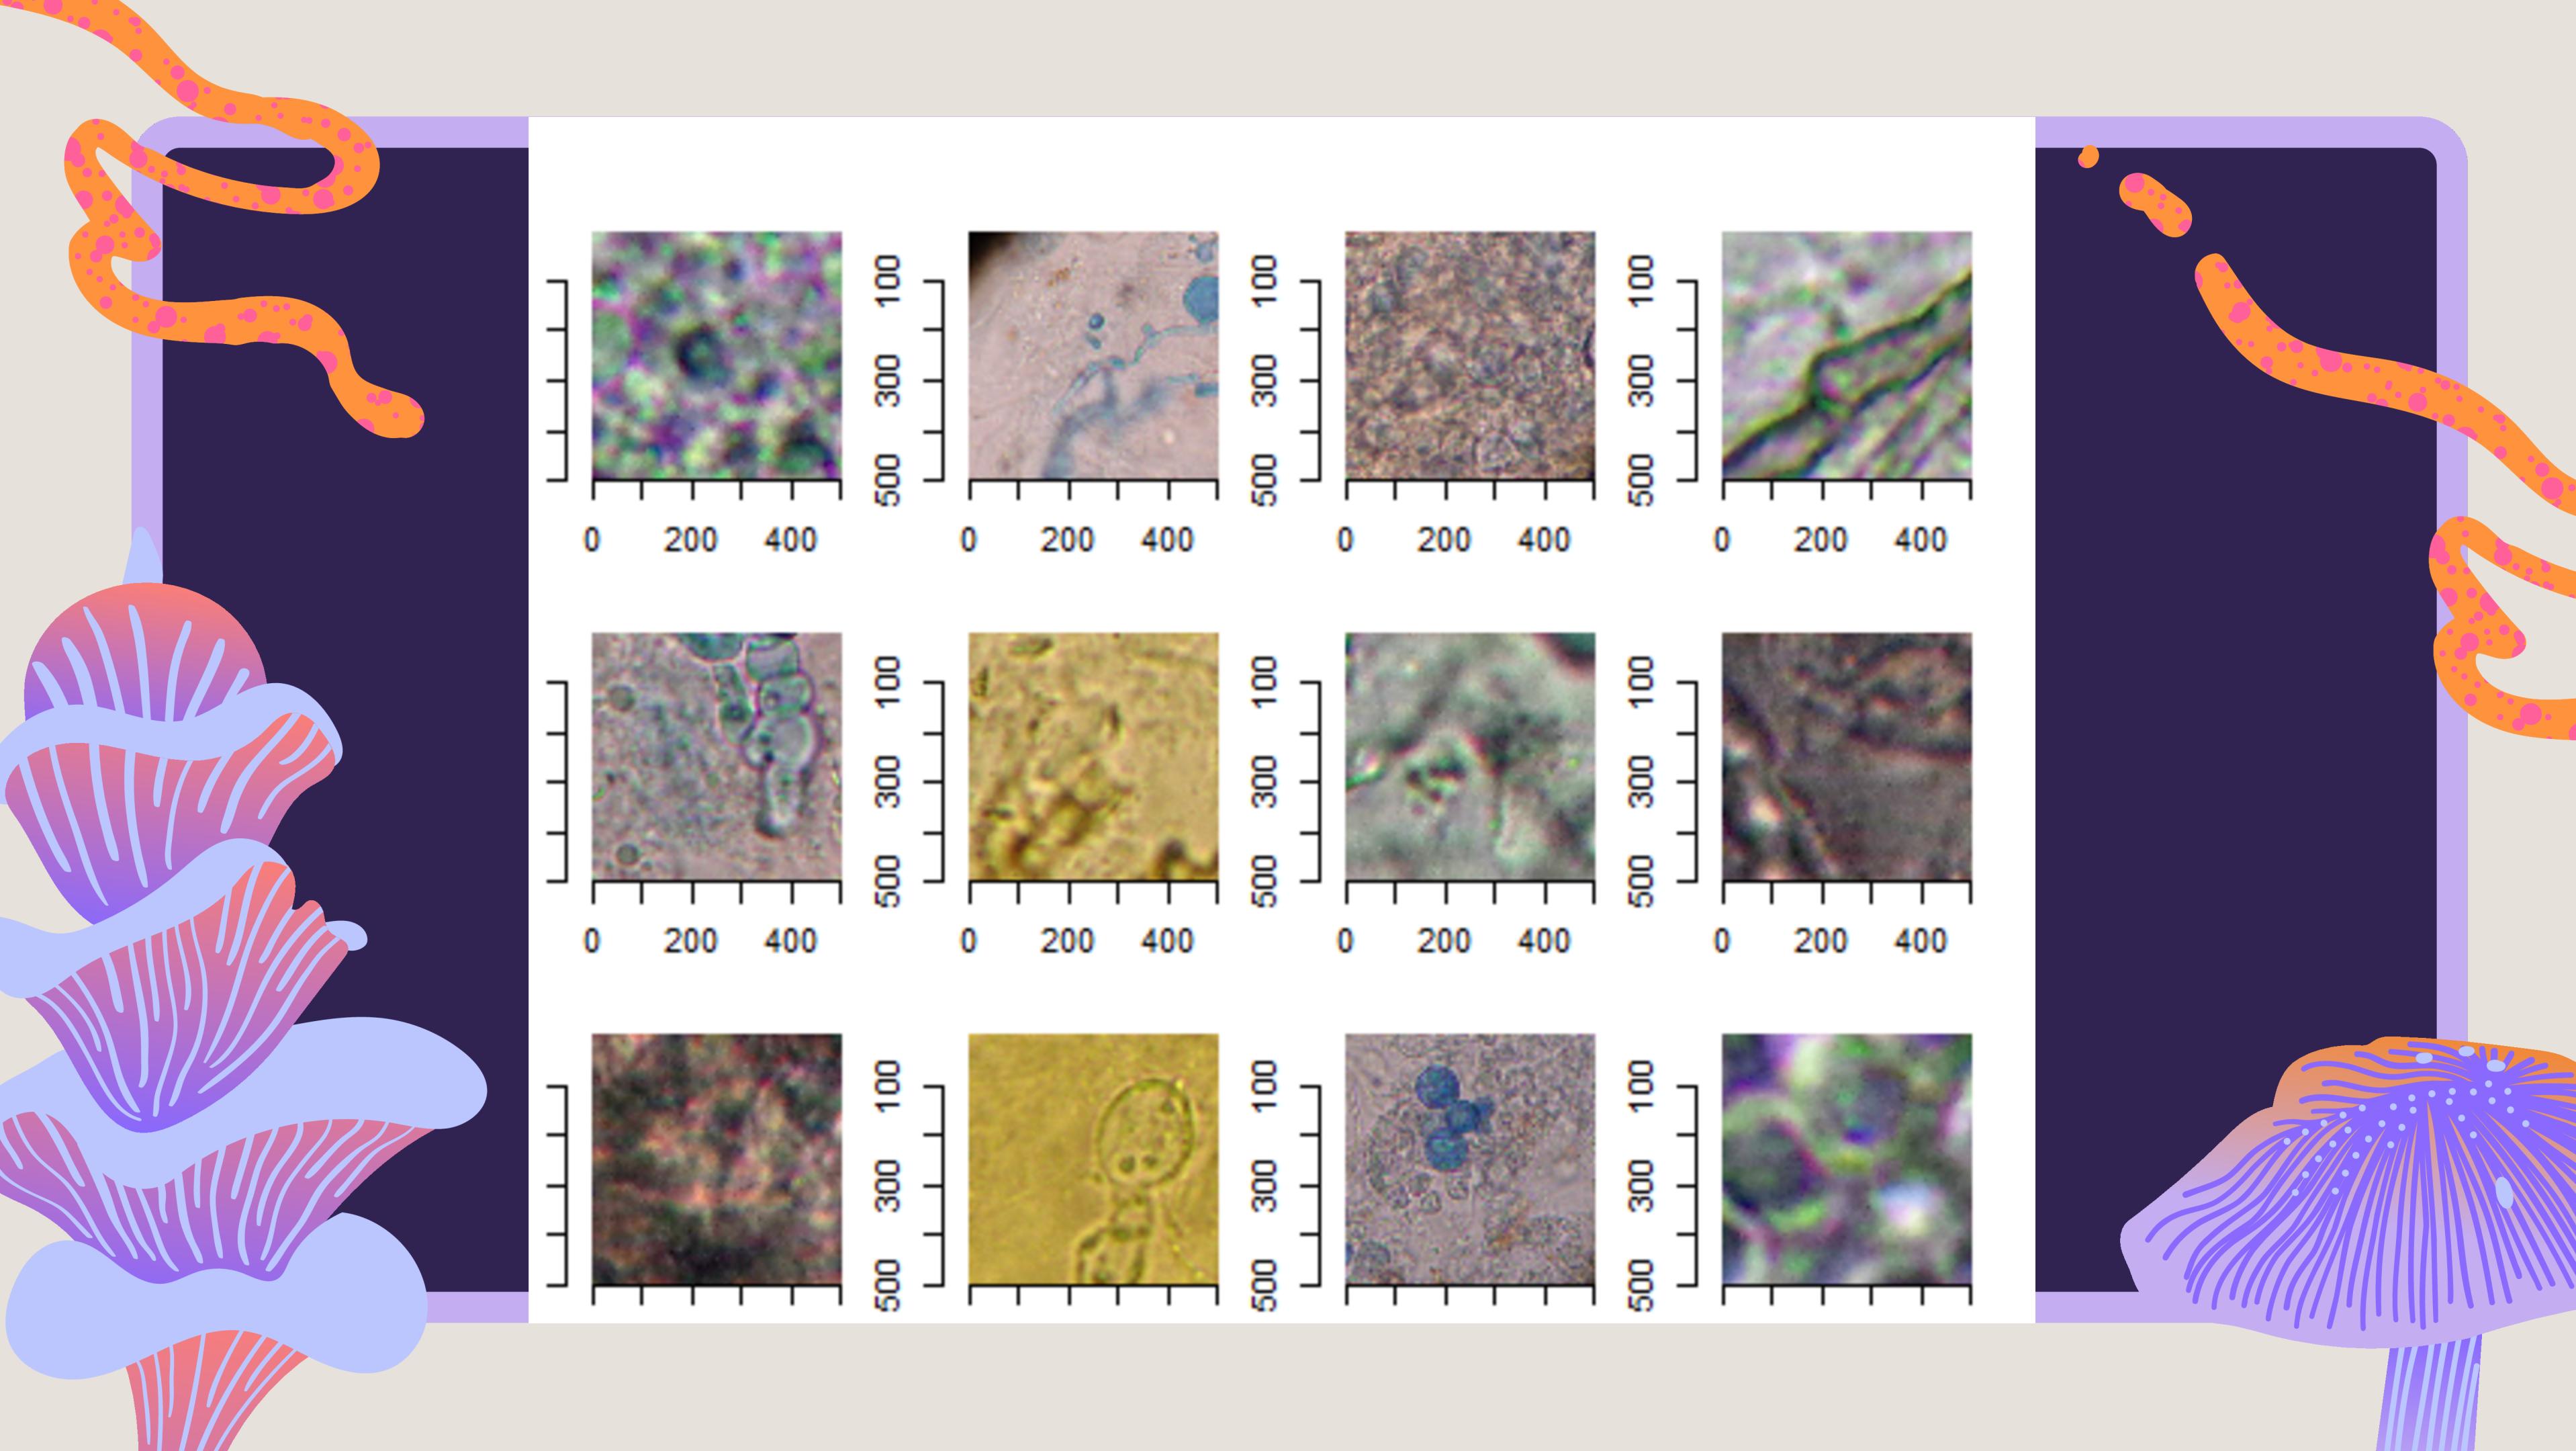
- LAS CATEGORÍAS H1 Y H2 ESTÁN MUY CARGADAS
- LAS MUESTRAS DE H3, H5 Y H6 SON MUY BAJAS
- DESBALANCE EVIDENTE



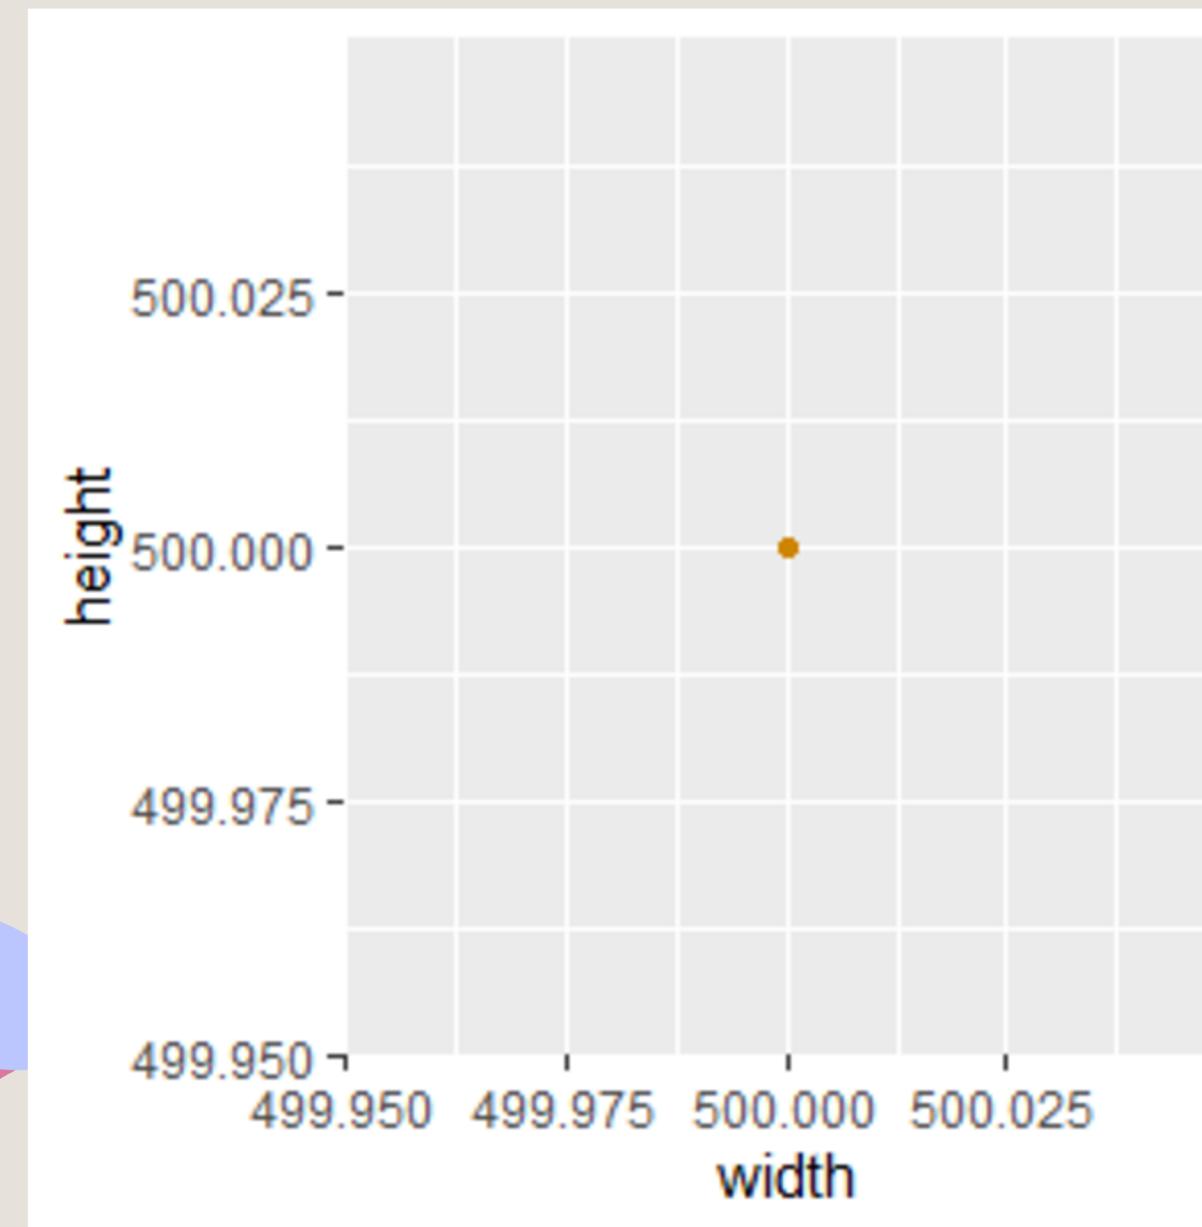
PREPROCESAMIENTO: BALANCEO DE CLASES



- SE FIJARON LAS CATEGORÍAS EN 1000 CADA UNA
- SE TOMÓ UNA M.A.S. SIN REPOSICIÓN EN LAS CATEGORÍAS GRANDES
- SE TOMÓ UNA M.A.S. CON REPOSICIÓN EN LAS CATEGORÍAS PEQUEÑAS PARA HACER DATA AUGMENTATION



ANÁLISIS EXPLORATORIO: DIMENSIONES



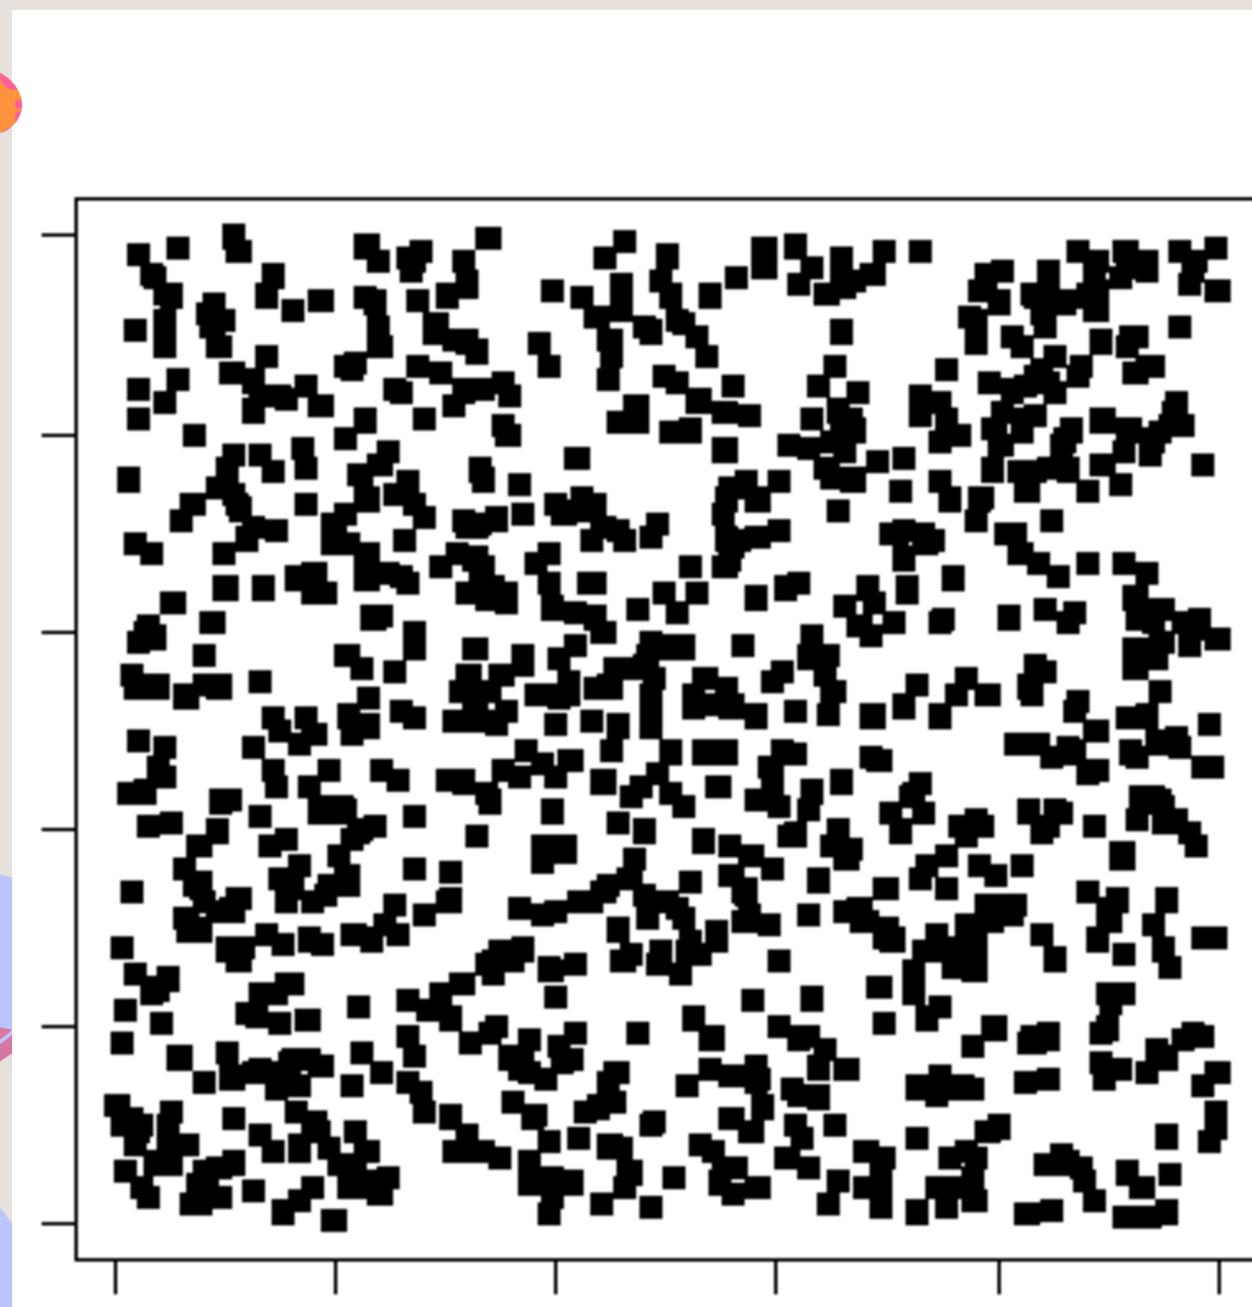
- LAS IMÁGENES FUERON
PREPROCESADAS POR LOS
INVESTIGADORES QUE
RECOPILARON LAS IMÁGENES
- FORMATO ESTÁNDAR
- ALTO: 500
- ANCHO: 500

Análisis Exploratorio: Colores

- LOS INVESTIGADORES QUE TOMAN LAS IMÁGENES APLICAN DISTINTOS PIGMENTOS PARA DESTACAR LOS ELEMENTOS QUE LES INTERESAN
- HAY IMÁGENES DE TONOS RADICALMENTE DISTINTOS EN EL DATASET, INCLUSO DENTRO DE UNA MISMA CATEGORÍA
- SI EL IMPACTO DEL COLOR ES FUERTE PODRÍA OCURRIR QUE LA CNN CLASIFIQUE SEGÚN ÉSTE Y NO SEGÚN LA FORMA DEL HONGO

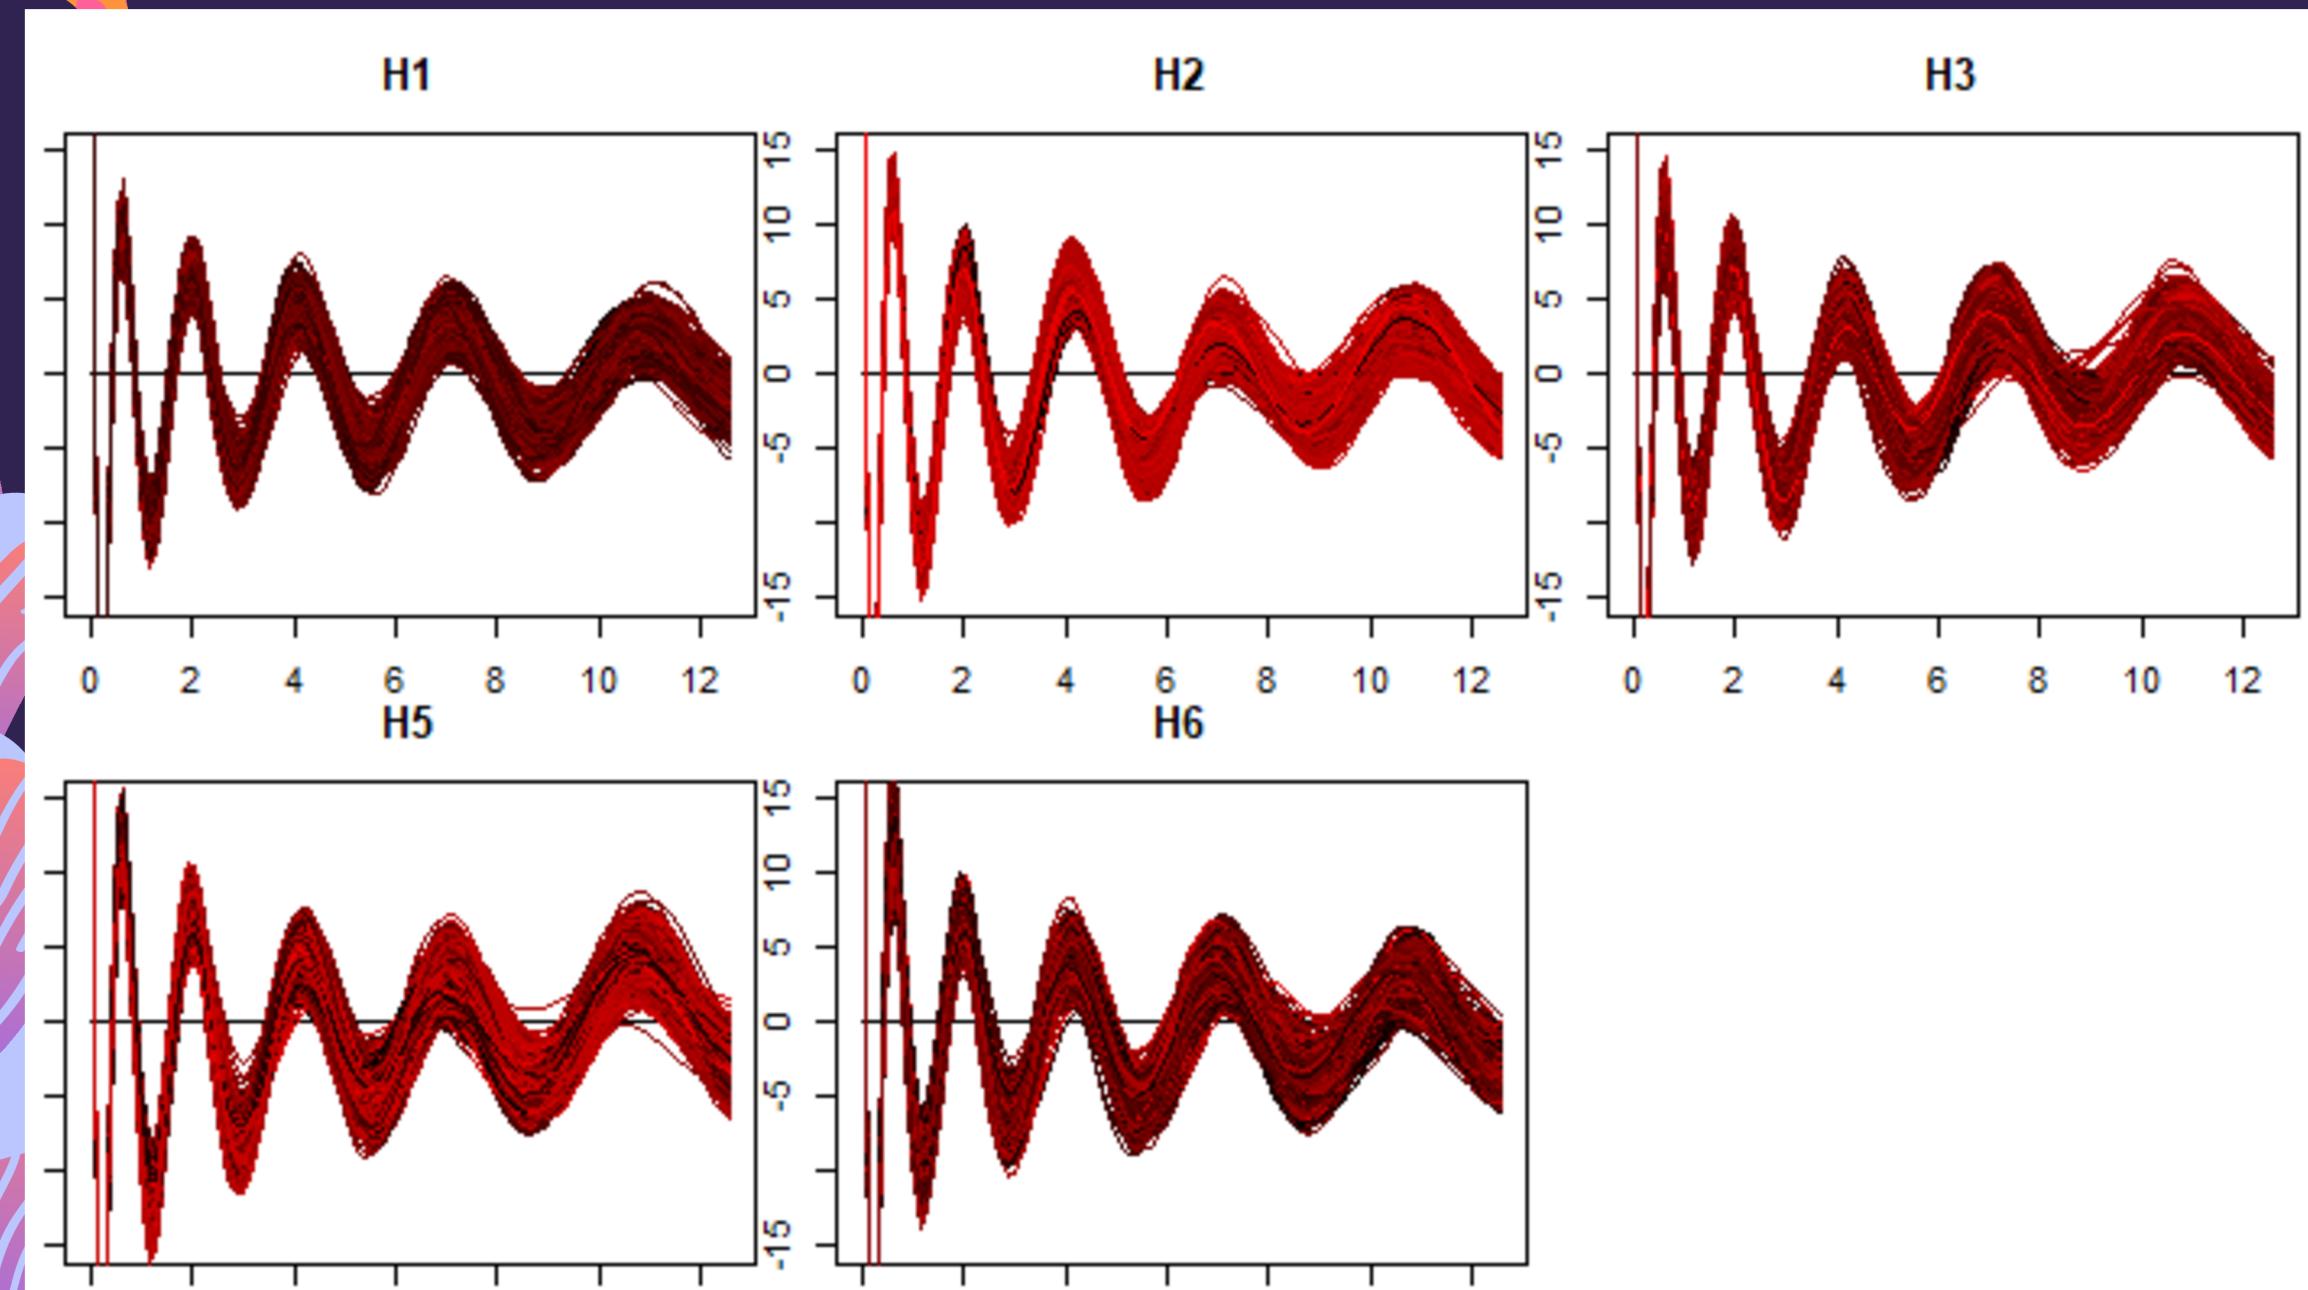


ANÁLISIS EXPLORATORIO: COLORES



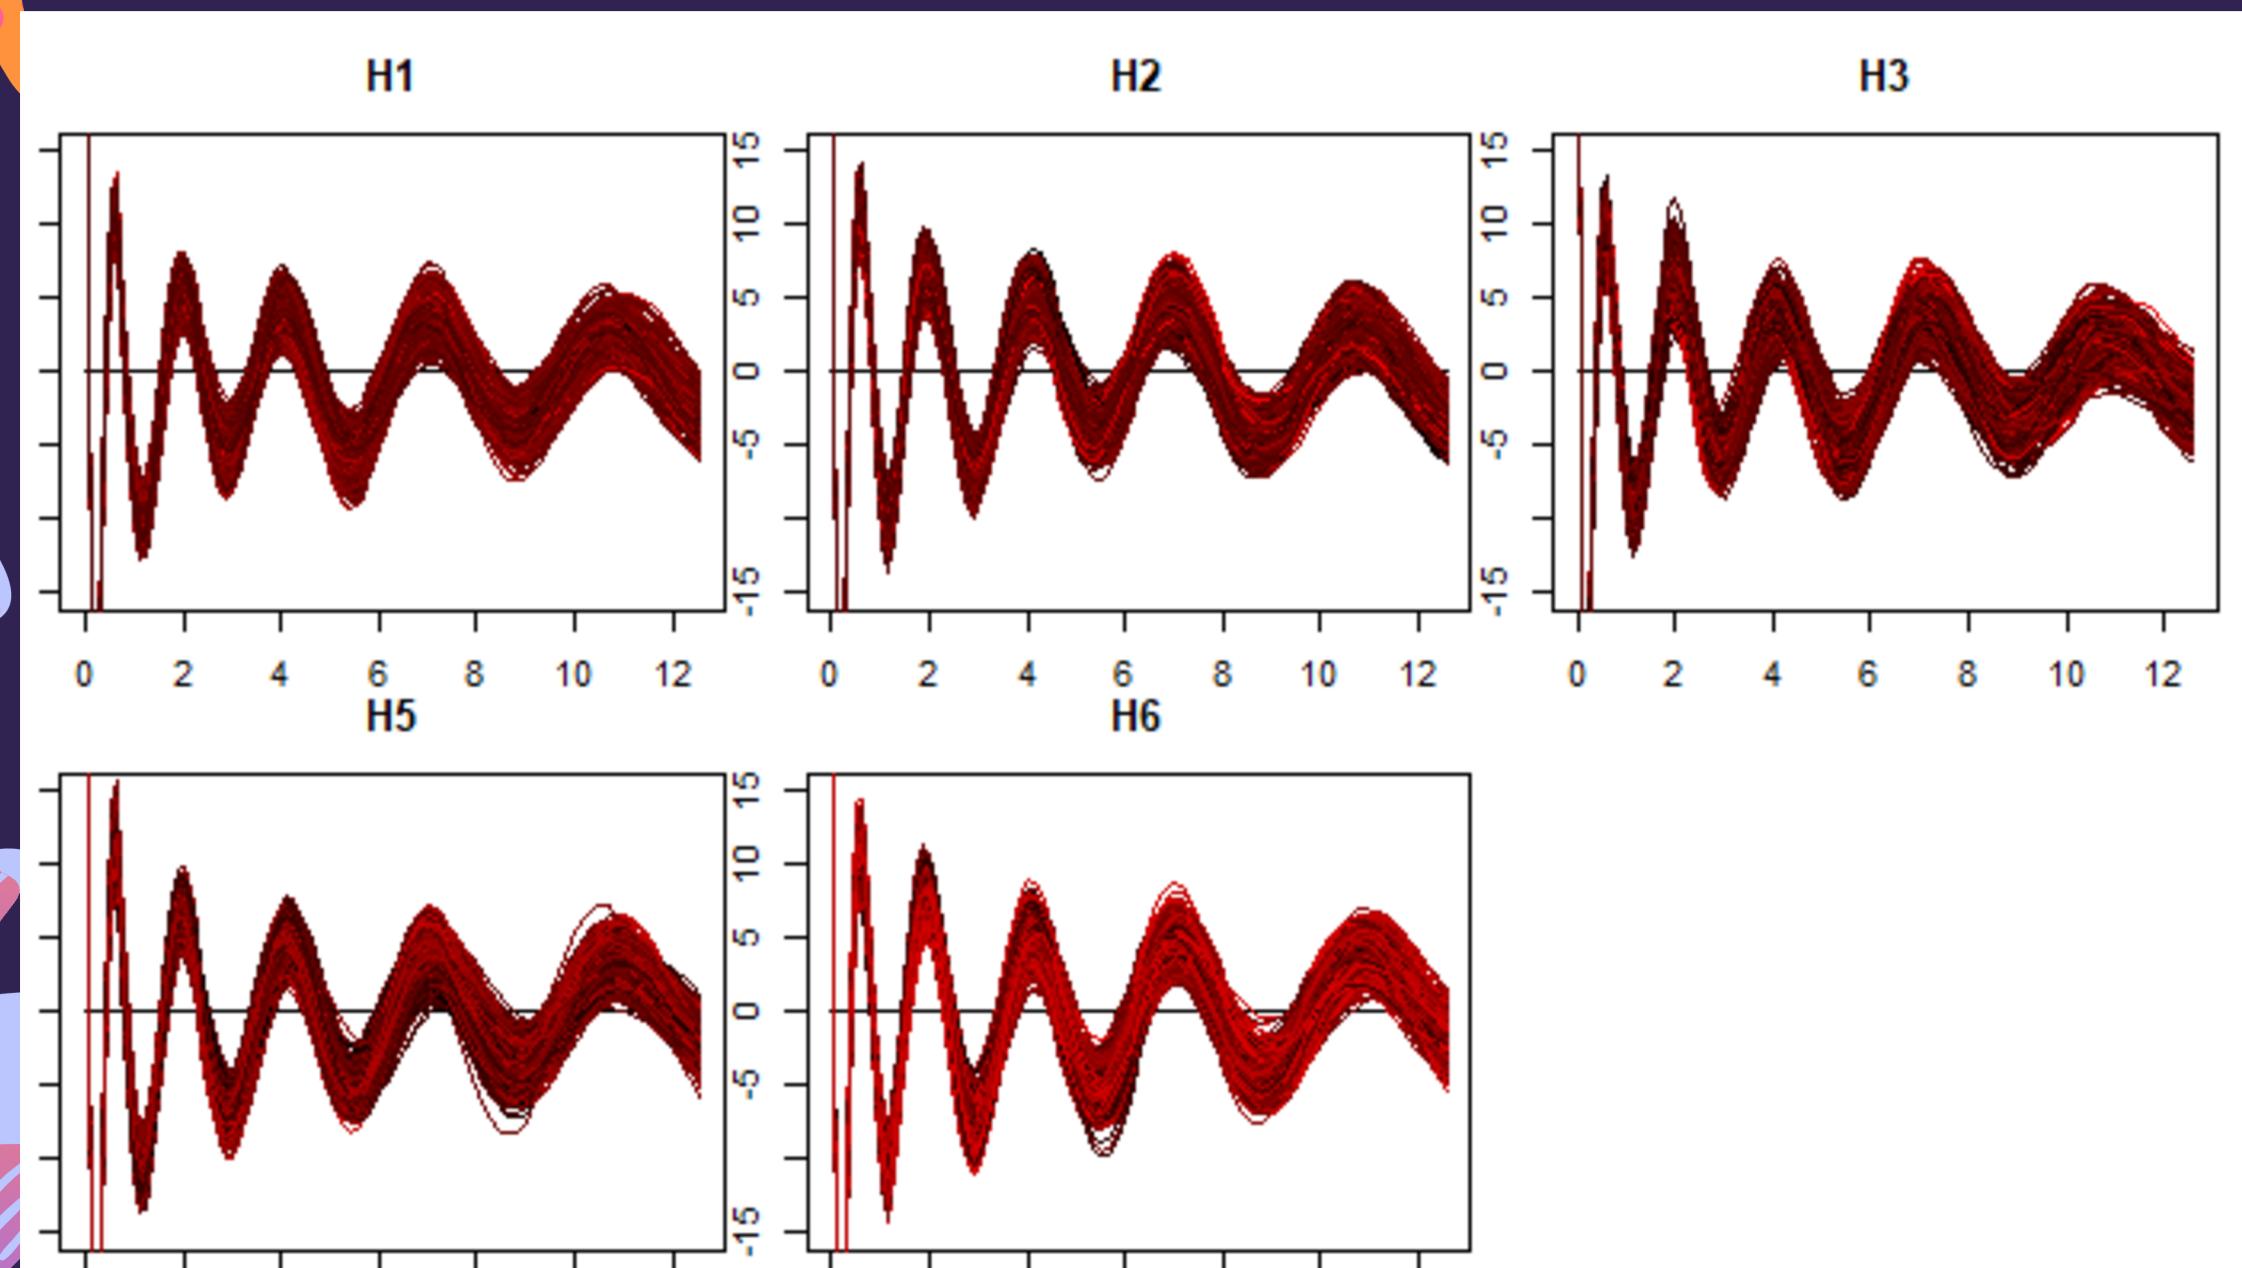
- PARA PROFUNDIZAR EN EL IMPACTO DEL COLOR, SE BUSCA ANALIZAR LOS VALORES RGB DE LOS PIXELES DE CADA IMAGEN
- SE TOMÓ UNA M.A.S SIN REPOSICIÓN DE 100 IMÁGENES DE LA MUESTRA ANTERIOR
- SE TOMÓ UNA M.A.S SIN REPOSICIÓN DE 1000 PIXELES DE LOS 250.000 POSIBLES DE LA SUBMUESTRA DE 100 IMÁGENES

Análisis Exploratorio: Color Rojo



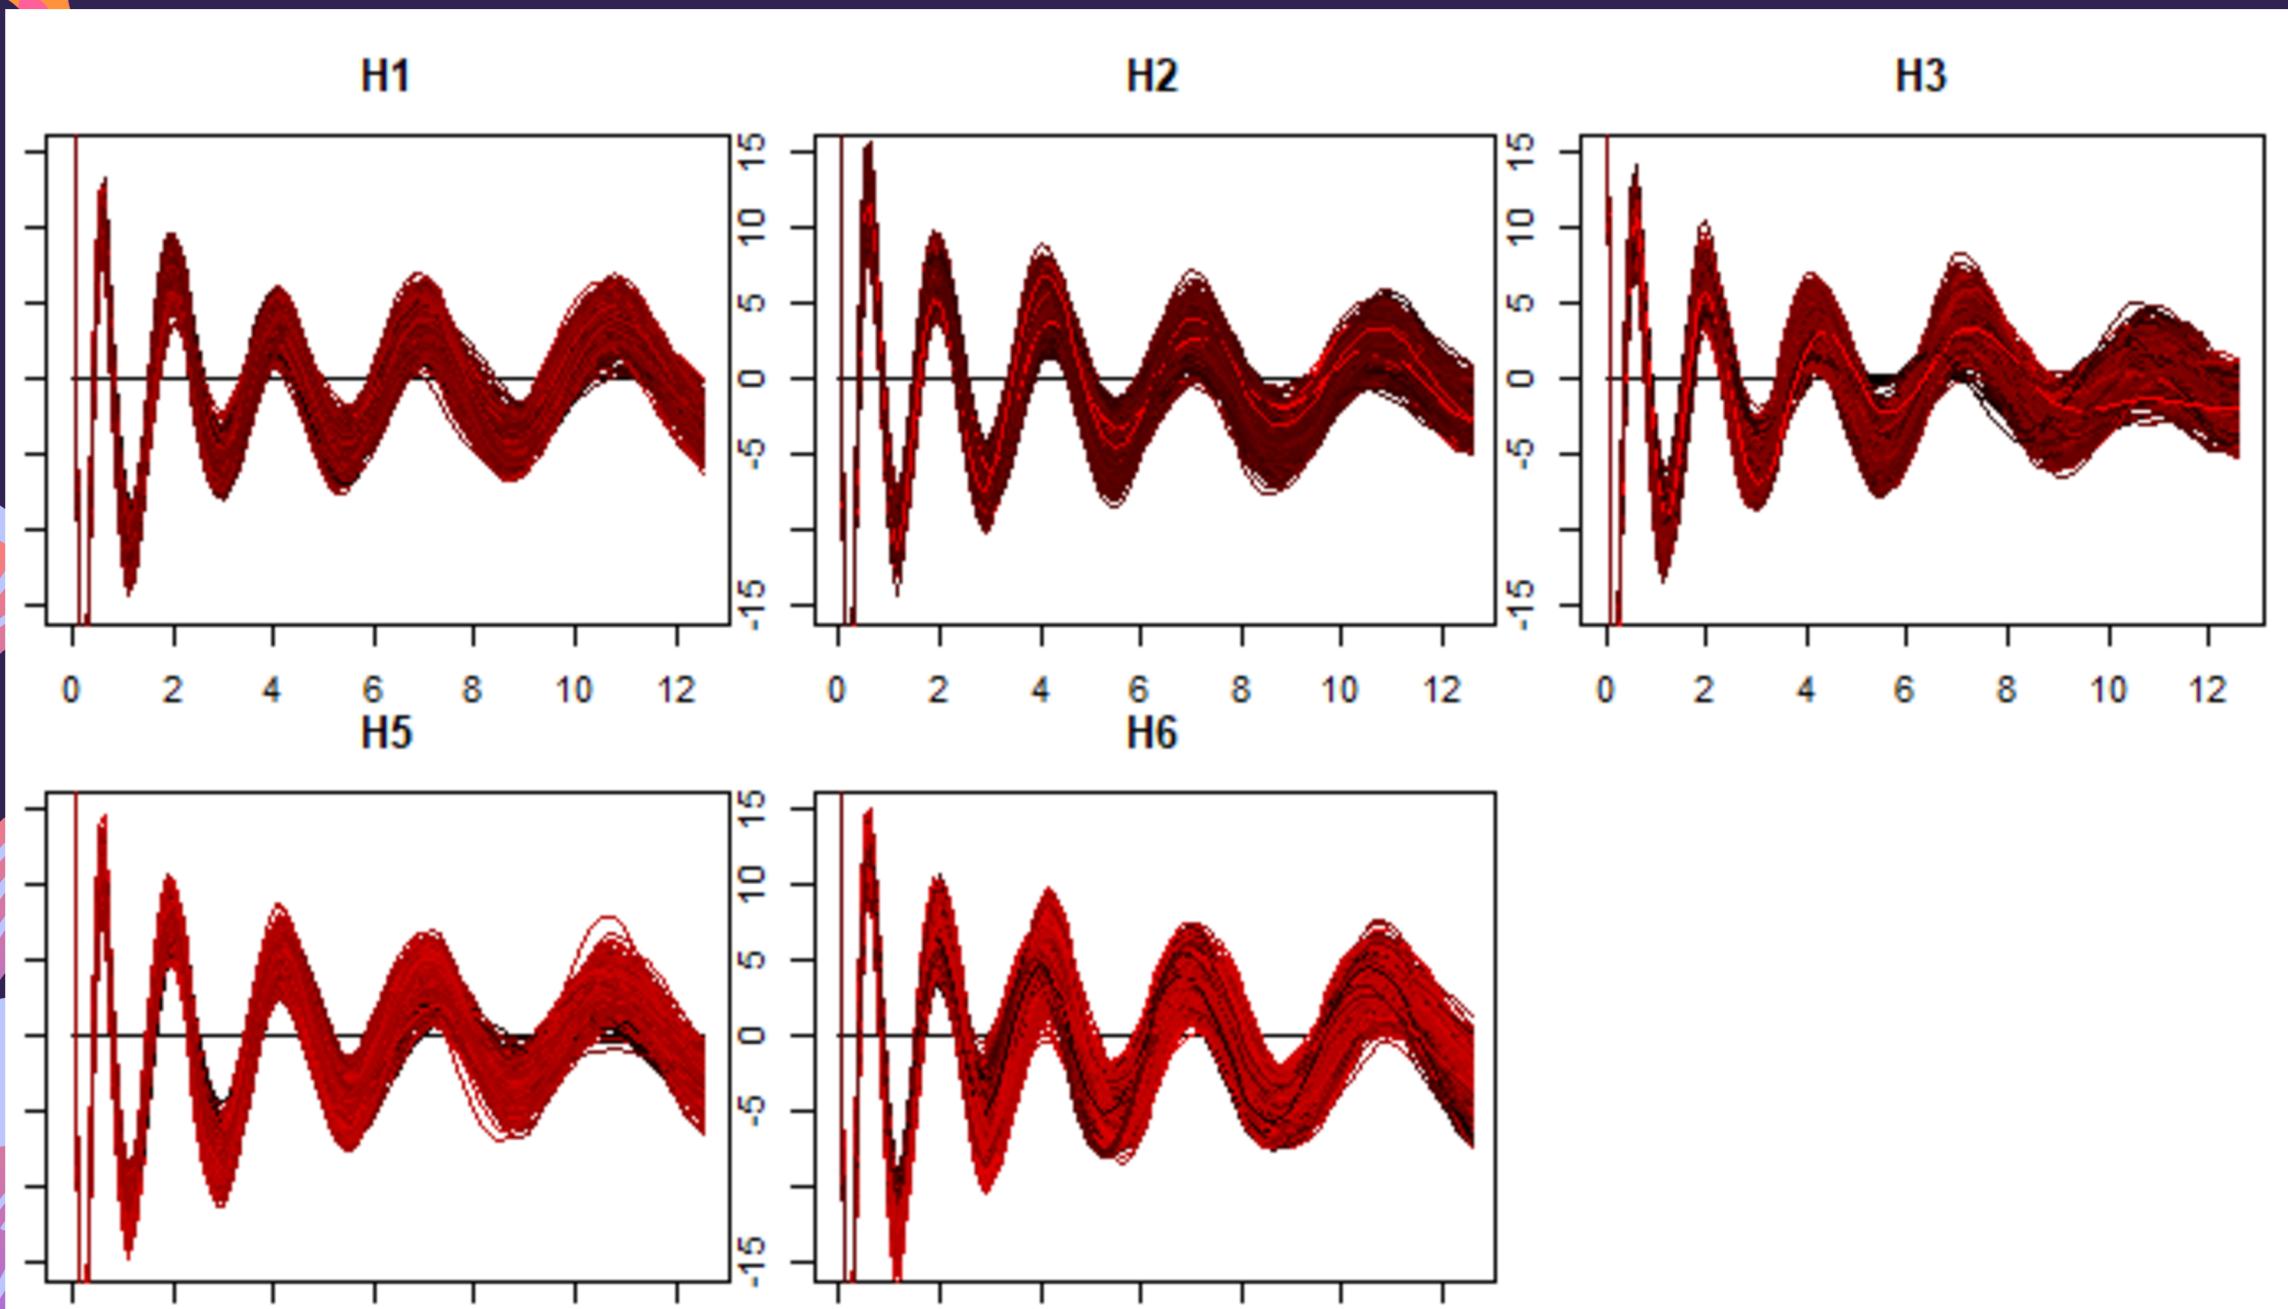
- H1 Y H5 PRESENTAN PATRONES CONSISTENTES
- H3 Y H6 PRESENTAN MÁS VARIABILIDAD
- H6 PRESENTA UN INICIO MÁS EXTREMO

Análisis Exploratorio: Color Verde



- H2 PRESENTA PATRONES CONSISTENTES
- H3 PRESENTA MÁS VARIABILIDAD
- H5 PRESENTA UN INICIO MÁS EXTREMO

Análisis Exploratorio: Color Azul



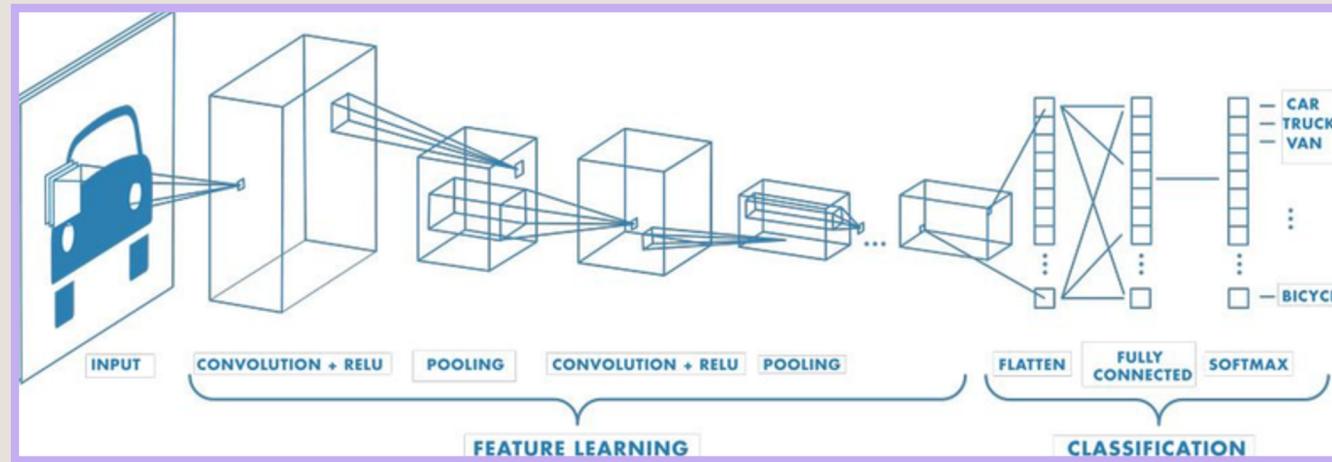
- H1 Y H6 PRESENTAN PATRONES CONSISTENTES
- H3 PRESENTA GRAN VARIABILIDAD
- H2 Y H6 PRESENTAN UN INCIO MÁS EXTREMO

ANÁLISIS EXPLORATORIO: COLORES

- HAY INDICIOS (MUY VAGOS) DE QUE LAS DISTRIBUCIONES DE COLORES CAMBIAN SEGÚN LA CATEGORÍA
- PODRÍA SER BUENA IDEA AJUSTAR EL MODELO EN ESCALA RGB Y GRISES



MODELO DE RED NEURONAL CONVOLUCIONAL

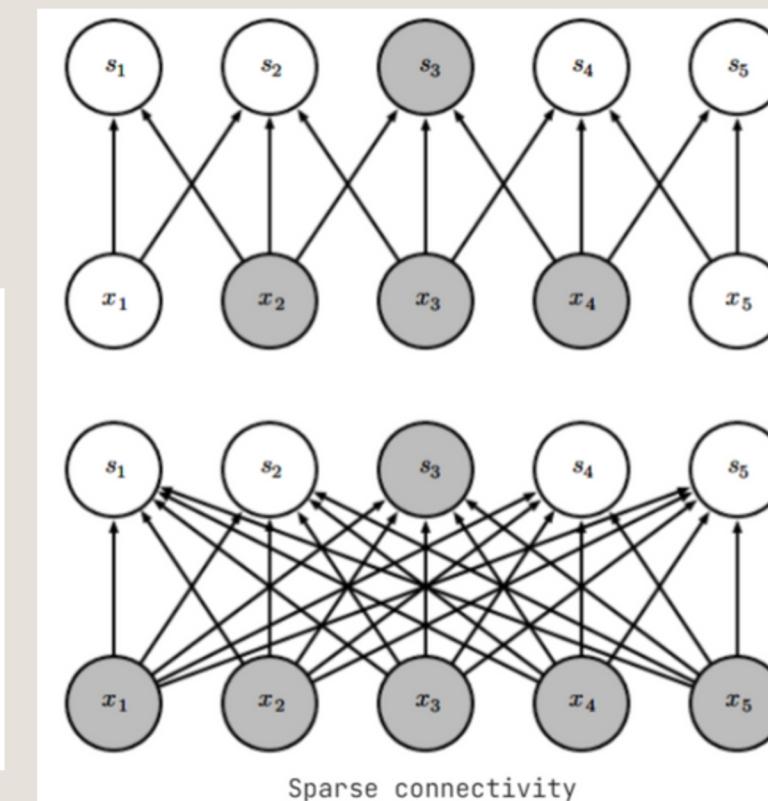


- CONVOLUCION

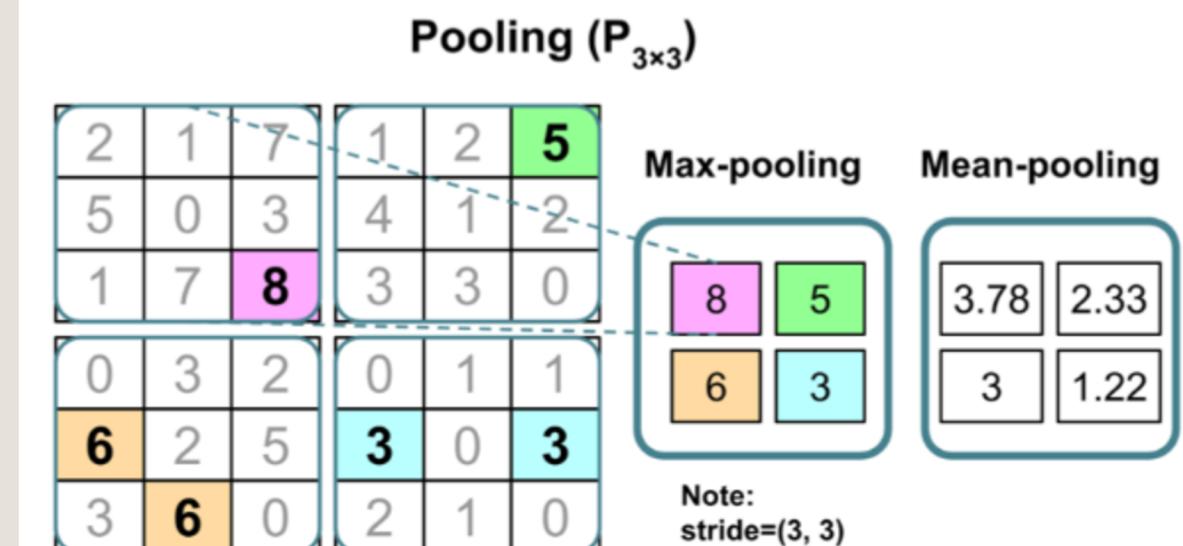
$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n)K(i - m, j - n)$$

$$S(i, j) = (K * I)(i, j) = \sum_m \sum_n I(i - m, j - n)K(m, n)$$

- SPARSE CONNECTIVITY



- POOLING



POST PROCESAMIENTO

- EL OBJETIVO ES HACER PREDICCIÓN MULTICLASE (5 CATEGORÍAS), HAY QUE TRANSFORMAR EL INPUT DEL MODELO EN UN VECTOR DE 5 PROBABILIDADES

- FUNCIÓN DE SALIDA -
SOFTMAX

$$\sigma: \mathbb{R}^K \rightarrow (0, 1)^K$$

$$\sigma(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

$$\mathbf{z} = (z_1, \dots, z_K) \in \mathbb{R}^K$$

- FUNCIÓN DE PÉRDIDA -
CATEGORICAL CROSS ENTROPY

$$L(y, \hat{y}) = -\frac{1}{N} \sum_i^N \sum_j^C y_{ij} \log(\hat{y}_{ij})$$

RESUMEN Y PRÓXIMOS PASOS

- SE IMPLEMENTARÁ UN MODELO DE CNN QUE CLASIFIQUE IMÁGENES EN 5 CATEGORÍAS
- CONSIDERAREMOS UNA IMPLEMENTACIÓN PARA LAS IMÁGENES EN ESCALA RGB Y DE GRISES
- EVALUACIÓN Y SELECCIÓN DEL MEJOR MODELO



REFERENCIAS

- UCI MACHINE LEARNING REPOSITORY. (N.D.). DEFUNGI. RETRIEVED DECEMBER 19, 2024, FROM [HTTPS://ARCHIVE.ICS.UCI.EDU/DATASET/773/DEFUNGI](https://archive.ics.uci.edu/dataset/773/DEFUNGI)
- GEEKSFORGEEKS. (N.D.). CONVOLUTIONAL NEURAL NETWORK (CNN) IN MACHINE LEARNING. RETRIEVED DECEMBER 19, 2024, FROM [HTTPS://WWW.GEEKSFORGEEKS.ORG/CONVOLUTIONAL-NEURAL-NETWORK-CNN-IN-MACHINE-LEARNING/](https://www.geeksforgeeks.org/convolutional-neural-network-cnn-in-machine-learning/)
- ZIELIŃSKI, B., SROKA-OLEKSIAK, A., RYMARCYK, D., PIEKARCZYK, A., & BRZYCHCZY-WŁOCH, M. (2020). DEEP LEARNING APPROACH TO DESCRIBE AND CLASSIFY FUNGI MICROSCOPIC IMAGES. PLOS ONE, 15(6), E0234806. [HTTPS://DOI.ORG/10.1371/JOURNAL.PONE.0234806](https://doi.org/10.1371/journal.pone.0234806)
- RAWAT, S., BISHT, B., BISHT, V., RAWAT, N., & RAWAT, A. (2024). MEFUNX: A NOVEL META-LEARNING-BASED DEEP LEARNING ARCHITECTURE TO DETECT FUNGAL INFECTION DIRECTLY FROM MICROSCOPIC IMAGES. FRANKLIN OPEN, 6, 100069. [HTTPS://DOI.ORG/10.1016/J.FRANKLINOP.2023.100069](https://doi.org/10.1016/j.franklinop.2023.100069)
- HANGARGE, M. (2023). DEEP LEARNING-BASED CLASSIFICATION OF MICROSCOPIC FUNGI FOR AGRICULTURE APPLICATION. EN R. MANZA ET AL. (EDS.), ADVANCES IN COMPUTER VISION, ARTIFICIAL INTELLIGENCE AND TECHNOLOGIES (ACVAIT 2022) (PP. 546-560). ATLANTIS PRESS. [HTTPS://DOI.ORG/10.2991/978-94-6463-196-8_42](https://doi.org/10.2991/978-94-6463-196-8_42)
- PLAZA, F. (N.D.). DEEP LEARNING: EXAMPLES 02B. RETRIEVED DECEMBER 19, 2024, FROM [HTTPS://FRANPLAZA.GITHUB.IO/COURSES/DEEP_LEARNING/DEEP_LEARNING_03_EXAMPLES_02B.HTML](https://franplaza.github.io/courses/deep_learning/deep_learning_03_examples_02b.html)
- GOODFELLOW, I., BENGIO, Y., & COURVILLE, A. (2016). DEEP LEARNING. MIT PRESS.